

SEMINAIRE DESIGNING TOMORROW - ESCP BUSINESS SCHOOL

BIG DATA : COMMENT L'EMPÊCHER DE DEVENIR UN CHEVAL DE TROIE

Jacques GIRARD - Gauthier JEANNIN - Corentin LECONTE
Alexandre O'NEILL - Enzo TOUAK - Hugo WEI
Sous la supervision de Caroline VERZAT



NOUS REMERCIONS

Isabelle BEYNEIX, professeur en Droit des Affaires, spécialiste dans le traitement des données personelles

Max MÉTRAL, ancien Insights Analyst en Formule 1 et pour Manchester City

Pierre GIRARD, chef de la division des services liés au tourisme à la direction générale de l'INSEE

Etienne WINDELS, Software Engineer chez Criteo

Camille (nom de famille non divulgué pour cause d'anonymat), étudiant en Master en Data & AI à HETIC, ancien stagiaire à Facebook

Caroline VERZAT qui a supervisé nos travaux

Et enfin l'**ESCP Business School** pour nous avoir donné les moyens de mener à bien ce rapport.

SOMMAIRE

Sommaire

REVUE DE PRESSE *5*

INTRODUCTION *13*

CARTE DES ACTEURS *16*

I. Les problèmes soulevés par le Big Data *17*

A. Les problèmes environnementaux du Big Data **17**

1. La pollution numérique : le fléau du XXIème siècle **17**

2. Le problème des data centers **18**

3. Des solutions pour réduire la pollution liée au Big Data ? **19**

4. Le Big Data : une réponse à la crise environnementale ? **20**

B. La question de l'éthique **22**

1. Quels problèmes de nature éthique le Big Data soulèvent-t-il ? **22**

Quelle réglementation sur la donnée ? **24**

C. Un Big Data qui pourrait représenter un danger pour nos démocraties **29**

1. La maîtrise du Big Data est au cœur des stratégies de puissances dites « révisionnistes », qui s'opposent à nos démocraties, et qui en font l'axe majeur de leur montée en puissance **29**

2. Le Big Data représente un danger pour les démocraties européennes **30**

3. L'omniprésence du Big Data semble indiquer que nous sommes entrés dans « l'âge du capitalisme de surveillance » (Shoshana Zuboff) **31**

II. Les apports au quotidien du Big Data *34*

A. Les apports du Big Data dans le sport **34**

1. Le sport n'a pas échappé à l' « ère du Big Data » **34**

2. Le Big Data : une réelle plus-value pour le sport grâce au "sport analytics" **35**

3. "Business Analytics": le deuxième type d'analyse dans l'industrie du sport **38**

4. L'émergence du Big data condamne-t-elle l'instinct et le plaisir sportif ? **40**

B. Le Big Data et la Santé **42**

1. La collecte des données **44**

2. L'utilisation des données en médecine **47**

3. Les limites **50**

C. Le Big Data représente un avantage certain pour les entreprises 53

1. La connaissance du consommateur 53

2. La gestion des risques 54

3. Le problème de concurrence deloyale 56

III. L'évolution du Big Data peut-elle permettre de répondre aux enjeux sociétaux ? 58

A. Que faire dans les faits? Quelle gouvernance pour le Big Data? 58

1. Une ressource détenue par des acteurs privés 58

2. Mise en place d'un cadre légal 59

3. Obtenir une classification des algorithmes comme nouvelle approche de la régulation des outils issus du Big Data 61

4. "Anonymiser" la Data, une réponse de la recherche au problème de la gestion des données 62

5. Vers une Data gérée par des citoyens? 62

B. Les limites du Big Data 64

1. Une solution coûteuse 64

2. Les risques technologiques et le manque de transparence 66

3. Le danger d'une gouvernance opaque, qui rejette l'individualité 69

C. Vers un bien partagé ? 71

1. La question du bien commun 71

2. Qu'entend-on alors concrètement quand on parle des réseaux de données comme bien commun ? 71

3. Quels avantages pourraient tirer les sociétés si les réseaux de données devenaient un bien commun ? 72

4. Pourquoi les réseaux de données ne deviennent-ils donc pas des biens communs ? 73

CONCLUSION 75

ANNEXES 77

1. Les interviews 77

2. La bibliographie 88

REVUE DE PRESSE

Le Big Data est défini comme un ensemble de données complexes, de nature et de sources parfois très différentes (bases de données personnelles, images satellites, images caméra, commentaires sur internet…) impossible à analyser à l'aide des méthodes classiques. Depuis 2014, ces données sont classées à l'aide de 8 critères qui permettent d'en évaluer la qualité : les 8 V, à savoir leur volume, type (variety), vitesse, véracité, valeur, variabilité, densité (viscosity) et leur viralité. La nécessité de traiter ces data et les perspectives qu'offrent leur traitement et leur visualisation a donné naissance à de nombreuses opportunités économiques et à un nouveau marché essentiellement composé de trois secteurs : les infrastructures (data centers), l'organisation et l'analyse (logiciels de traitement), et le service (business consulting). Dans cette revue de la littérature, nous tenterons de cerner les principaux liens entre le Big Data et les objectifs du développement durable, afin de déterminer dans quelle mesure le Big Data peut apporter des solutions aux problématiques de développement, d'écologie. Nous exposerons également les risques liés à l'utilisation d'une telle technologie et les recherches en cours afin de les limiter.

I. Le Big Data comme un atout pour protéger l'environnement pour les gouvernements, les ONG et certaines entreprises

Le Big Data offre des perspectives pour faire baisser l'empreinte carbone, à l'instar de la Chine qui l'utilise pour réduire les émissions de CO2 dans les supply chain. Certaines entreprises utilisent le Big Data pour sélectionner le fournisseur le moins polluant. De manière générale, le Big Data pourrait également permettre un allongement de la vie des appareils numériques, grâce à une meilleure compréhension de leurs défaillances, ce qui in fine réduirait la consommation énergétique liée à la production de ces derniers.

Le traitement des données permet aussi une meilleure compréhension des phénomènes et catastrophes naturels et aide à mieux les appréhender.

Le Big Data permet aussi un contrôle de l'étalement urbain, cause de nombreux problèmes d'infrastructure en Asie du Sud et permet la construction en Chine et en Corée du Sud de « Smart Cities », villes nouvelles compatibles avec la transition écologique.

Plusieurs ONG de la protection de l'environnement utilisent également le Big Data pour œuvrer à la protection de l'environnement.

II. Le risque écologique lié à l'utilisation du Big Data et les recherches visant à le limiter

La croissance du nombre d'équipements électroniques pose un problème pour l'environnement, en 2019, on compte non moins de 34 milliards d'équipements pour 4,1 milliards d'utilisateurs (soit plus de 8 équipements par utilisateur). Ces derniers sont répartis entre l'utilisation directe par les utilisateurs, celle par le réseau et enfin celle par les centres informatiques (ou data centers). Par son importance, le numérique peut aujourd'hui être considéré comme un « 7e continent » avec une empreinte environnementale entre 3 et 5 fois plus importante que la France (en fonction des indicateurs). De façon purement factuelle, le numérique consomme 4,2% des ressources d'énergie primaires, contribue à hauteur de 3,8% dans les émissions de gaz à effet de serre, compte pour 0,2% de la consommation d'eau au niveau mondial et pour 5,5% de la consommation d'électricité. Enfin, au sein de cet impact environnemental lourd, c'est avant tout la fabrication des équipements qui pèse avec plus de 30% de l'impact total (voire 60% si l'on y ajoute l'électricité nécessaire à la production).

On estime qu'entre 2010 et 2025, l'empreinte environnementale du numérique sera amenée à doubler voire tripler en passant notamment de 2,5% des émissions de gaz à effet de serre mondiales à plus de 6%. Les raisons principales expliquent cette montée en puissance du poids du numérique sur l'environnement sont avant tout :

- L'augmentation de l'utilisation d'objets connectés, on estime qu'en 2025 nous utiliserons 48 fois plus d'objets connectés qu'en 2010. Ils représenteront alors entre 27 et 43% du bilan du numérique contre moins de 10% avant 2010.
- L'augmentation de la taille des écrans qui a doublé depuis 2010.
- Une amélioration de l'efficience énergétique des appareils qui devient insuffisante, on constatera sûrement un triplement de la consommation d'électricité par le numérique d'ici 2025, par rapport à 2010.
- L'utilisation croissante du numérique par les pays émergents.

Dans ce cadre, produire plus de matériel de stockage de données, adapté au big data et extrêmement énergivore peut apparaître dangereux.

Le problèmes des Data Centers :

Le nombre de data centers est en constante augmentation, on en compte plus de 4000 de nos jours. Les data centers utilisent chaque année autant d'électricité qu'un pays développé, cette consommation pourrait atteindre les 10% de l'électricité mondiale (contre 4% aujourd'hui) d'ici 2030 (*2 tous les quatre ans). Ils émettent plus de gaz à effet de serre que le secteur aéronautique. Cette consommation excessive réside pour partie dans l'ignorance de la part des propriétaires de data centers des normes de température des serveurs : la plupart refroidissent de manière trop excessive.

L'innovation peut alors être la clé : déplacer les centres actuels vers de nouveaux centres dits hyperscales plus économes en énergie permettrait de réduire l'empreinte carbone des data centers. L'amélioration des techniques de refroidissement est aussi primordiale : localisation (pays froids), mise en veille ou IA, voici quelques solutions déjà existantes qui portent leurs fruits. La construction de systèmes plus résistants aux hautes températures est également une piste intéressante. Enfin, l'élaboration de systèmes dits "désagrégés" (dont les différentes pièces sont indépendantes) permet une plus grande longévité des pièces et matériaux. Les data centers hyperscales (DCH) sont des data centers de grande envergure qui s'adressent aux grandes entreprises telles que Google ou Amazon. Ils occupent également bien mieux l'espace disponible. Ils sont également dotés d'un meilleur indice de performance énergétique (PUE), souvent proche de 1, le refroidissement y est grandement optimisé. Les DCH s'adaptent également facilement aux innovations. Les DCH sont aussi plus sécurisés et s'implantent dans les déserts démographiques, là où l'électricité est la moins chère. De plus, les DCH sont constitués de manière à ce que chacune de leurs pièces puisse être remplacée indépendamment des autres. Enfin, l'électricité acheminée y est mieux répartie et les dispositifs de redondance d'alimentation, qui dépensaient inutilement de l'énergie y sont supprimés. L'IA a permis de réduire de 28% les émissions dans le secteur du bâtiment et son utilisation pourrait être étendue aux Data Centers.

Plus que les data centers eux-mêmes, c'est avant tout l'utilisation des nouvelles technologies qui a fait exploser les émissions de gaz à effet de serre : entre 2010 et 2018, la consommation par les data center à augmenté de 6% alors que la demande en stockage de données avait été multipliée par 6. Les mécanismes plus modernes de codage permettent également une meilleure appréhension des données, un traitement de ces dernières facilité et optimisé donc moins consommateur d'énergie.

Concernant le big data lui-même, il est possible de catégoriser les secteurs à réformer pour réduire son empreinte carbone :

- La production, collecte et transmission : il s'agirait à ce niveau de supprimer les données inutiles ou ayant peu d'importance, ou bien de les compresser.

- Le Stockage : augmenter l'efficience énergétique des data centers (cf Data Centers Hyperscales)

- L'analyse : métamorphoser l'architecture de traitement des données en la rendant plus efficace et moins gourmande en énergie, il en va de même pour l'administration des serveurs. La réduction des données à analyser permettra aussi mécaniquement un diminution de l'énergie utilisée par l'analyse.

Un cas concret : le système REDUX

Le système REDUX est un système de gestion de l'efficacité énergétique. Ce système est considéré comme une révolution car le techniques de gestion de l'énergie existantes pour les centres de données ne tiennent pas compte de l'utilisation des dispositifs d'alimentation sans interruption (ASI) comme source ou stockage d'énergie, ou ne tiennent pas compte de la nature des fluctuations de prix de l'alimentation du réseau. REDUX se démarque en incorporant un système d'ASI distribué adapté aux énergies renouvelables comme le solaire et l'éolien. Le but de REDUX est d'économiser la facture électricité tout en gardant la performance des Data centers. C'est une première avancée pour résoudre les problématiques liées aux data centers comme la caractéristique intermittente des énergies renouvelables et la croissance des data centers. Ces derniers risquent de doubler leur consommation

d'électricité tous les cinq ans. De plus, pour l'instant, l'électricité est produite en général par des méthodes à forte intensité carbone même s'il existe de plus en plus d'initiatives pour que les data centers soient alimentés avec des énergies vertes. La ferme solaire construite par Apple est un exemple. REDUX est capable de réguler la consommation en électricité et d'utiliser les avantages des énergies renouvelables qui peuvent rapidement augmenter leur capacité de production pour s'adapter aux besoins des data centers. Ce système ouvre la voie à des data centers modernes respectueux de l'environnement. Néanmoins, à travers différents modèles, REDUX a de l'avance sur ses concurrents, notamment par rapport au gain en énergie et sur le coût de cette dernière. Finalement, ce projet témoigne de la possibilité à l'avenir de réduire grandement la consommation des data centers qui sont des lieux très énergivores.

III. Perspectives et impact social :

Le Big Data apparaît comme un allié de la gestion des ressources dans un contexte de croissance démographique et d'accroissement de la population en milieu urbain. Il permettrait également de surveiller la pollution de l'air. En matière de politique publique, le Big Data a permis le déploiement de stratégies gouvernementales efficaces en termes de lutte contre les épidémies, la criminalité, de développement de l'agriculture durable, d'amélioration des services publics tels que les transports et de contrôle de la qualité de l'éducation, notamment dans les pays en voie de développement (ex : Ethiopie).

Le Big Data dans la médecine:

Au départ utilisé pour mieux cerner les profils des clients, le Big Data a permis une nette amélioration des services à la personne, notamment du point de vue médical. Les méthodes de collecte des informations permettent de synthétiser rapidement les dossiers médicaux, de transmettre au personnel hospitalier des analyses rapides et des constats sur la situation du patient. L'analyse des données permet également de faire progresser la recherche en permettant de prédire les comportements de la maladie et d'établir des diagnostics plus complets.

L’utilisation des Big Data présente cependant un risque en termes de qualité de la donnée, et en termes de sécurité.

L'utilisation du Big Data ne permet pas de combler une situation de manque de personnel soignant. Le Big Data a donc toujours un rôle complémentaire.

Le “Profilage”

Le "profilage" sociologique d'une population, qui consiste en une certaine forme de collecte, d'analyse et de publication d'informations sur les caractéristiques, les pratiques ou les opinions "objectives" des individus. Cela inclut les données sous forme de texte qui sont désormais largement accessibles via les médias sociaux et plus largement internet. En particulier, la protection des personnes physiques ne devrait pas être utilisée comme prétexte pour défendre le contrôle de l'utilisation des données par des acteurs économiques ou administratifs spécifiques.

Grâce au profilage, les entreprises pourraient adapter leur offre individuellement, c’est-à-dire savoir le prix que chaque consommateur est prêt à dépenser, compte tenu de ses préférences et de son revenu disponible. Cela aurait certains avantages : égalité de bien-être et de ressources, augmentation productivité ou encore bien être social. Mais il y a aussi des désavantages, notamment au niveau des égalités relationnelles. Le concept de tarif personnalisé semble injuste envers les consommateurs car il sape leur rôle de participants. On parle même de discrimination par les prix : on retrouve le même produit mais pas le même prix. La discrimination par les prix permet aux entreprises d'extraire un plus grand surplus de consommateurs mais est impossible dans un marché parfaitement concurrentiel. La personnification tarifaire est plus susceptible lors d’un monopole ou un oligopole. Toutefois, la personnification tarifaire peut générer certains avantages sociaux importants sur le plan éthique. Un tel marché peut conduire à une distribution plus égale du bien-être et des ressources. L’accumulation de ressources est plus difficile notamment pour les riches et plus accessible pour les plus pauvres donc c’est une solution plus équitable. De plus, on peut y voir un bien-être social : davantage de consommateurs sont servis. En 2000, Amazon avait déjà tenté l’expérience en vendant des DVD à des clients différents à des prix différents. De plus, il faut que cela attire un bénéfice social sous peine de mettre en colère la population. Il faut

par conséquent une certaine transparence sur la personnification. En outre, une entreprise est moralement contrainte d'avoir de la concurrence, ce qui n'est pas en accord avec le principe de tarification personnelle. De plus, cette pratique n'est pas éthique. Une fois que nous avons introduit les BDPP, les consommateurs ne peuvent plus utiliser les mécanismes de marché qui leur permettent de faire concurrence avec les entreprises en amenant les entreprises à se battre pour eux. Ceci est le principal problème de la tarification personnelle.

IV. Les perspectives économiques du Big Data : le cas du sport

À l'échelle mondiale, le marché du sport à un niveau professionnel représente plus de 90 milliards d'euros, soit un grand marché à capturer pour le Big Data. À l'image de l'industrie audiovisuelle qui utilise les audiences, la capacité d'améliorer l'expérience des joueurs, des fans et l'organisation d'évènements est largement facilitée par la data et son étude. Le premier exemple de projet démocratisé dans le sport lié au big data se déroule en 2002 aux Etats-Unis. Le manager des Athletics d'Oakland, une équipe de baseball moyenne, Billy Beane, met au point une formule révolutionnaire dans le monde du sport. En 2002, l'équipe fait face à la perte de ses meilleurs éléments et ne peuvent se permettre de dépenser trop d'argent à cause d'un budget trop limité par rapport aux grosses équipes de la ligue. Le manager de l'équipe décide donc d'adopter une démarche scientifique pour recruter les nouveaux joueurs de l'équipe. A l'aide d'un spécialiste, il met au point un algorithme qui trie de nombreuses données des différents joueurs de la ligue et permet de conseiller des joueurs qui iraient parfaitement à l'équipe. L'équipe a donc pu recruter des joueurs peu chers pour compléter leur équipe.

Quelles conséquences :

Record en 103-59 = superbe saison de l'équipe

Dès l'année d'après, toutes les autres équipes ont adopté cette méthode statistique pour les recrutements.

V. Le Big Data utilisé à des fins politiques

L'utilisation du Big Data lors des campagnes suscite un fort engouement pour les partis politiques, aussi bien nouveaux (En Marche) ou anciens (PS). Importée des Etats-Unis et médiatisée par l'affaire Cambridge Analytica, l'utilisation du Big Data pour influencer les électeurs ou adapter les stratégies de communication s'est aussi développée en France au détriment des considérations éthiques ou humaines.

Le Big Data, car regroupant une masse immense de données, permet de mieux cerner le profil des électeurs et de mieux communiquer avec eux.

Enfin, l'efficacité du Big Data pour la campagne électorale est encore sujette à caution et pourrait bien n'être qu'un prétexte pour les entreprises de collecte de données pour collecter des données qui seront revendues ou utilisées, et ceci malgré l'utilisateur.

INTRODUCTION

A l'origine du Big Data se trouve l'accroissement de la collecte des données. On peut penser aux cookies, aux données qu'enregistrent nos smartphones, mais aussi à toutes les données générées par l' "Internet of Things" (les objets connectés). Mais cela recouvre également des bases de données d'observations satellites, des images de tomates, des données techniques de matériaux… Ces données de nature diverses ont permis la mise en place d'algorithmes (que l'on désigne sous le nom de "Deep Learning" ou "Machine Learning"), entraînés à reconnaître les goûts des utilisateurs, à reconnaître les maladies sur les tomates, à reconnaître les signes annonciateurs de la météo, à prévoir les catastrophes climatiques, et tout cela avec une précision qui est des milliers de fois supérieure à la nôtre. Avant de poursuivre notre chemin, il est nécessaire de poser quelques notions autour du Big Data.

Le **Big Data** est défini comme un ensemble de données complexes, de nature et de sources parfois très différentes (bases de données personnelles, images satellites, images caméra, commentaires sur internet…). Ces ensemble sont souvent d'une taille gigantesque, ce qui les rend impossible à analyser à l'aide des méthodes classiques. L'essor d' "Internet of Things" (IoT) a contribué à alimenter et à complexifier ces données tout en offrant de plus grandes perspectives en termes de prédictions (Lawrance, 2021). L' **"Internet of Things"** désigne la multiplication des objets connectés, qui engendre des flux omniprésents de données et des bases de données de plus en plus complexes. Depuis 2014, ces données sont classées à l'aide de 8 critères qui permettent d'en évaluer la qualité : les 8 V, à savoir leur volume, type (variety), vitesse, véracité, valeur, variabilité, densité (viscosity) et leur viralité. Les **Big Data Analytics** (BDA) désigne les méthodes et les outils utilisés pour traiter les données afin d'établir des prévisions (Gudivada, 2017). Le Big Data sert à permettre le déploiement d'algorithmes de simulation et d'analyse, pour lesquels l'abondance des données est un facteur nécessaire. On sait depuis longtemps que le Machine Learning permet d'établir des catégories de consommateurs avec bien plus de précision que certains experts. James Marcus, dans le livre *Amazonia: Five Years at the Epicenter of the Dot.Com Juggernaut* (2004) présente déjà les exploits que réalisent les algorithmes du géant du web en termes de qualité

de recommandations aux clients.

La nécessité de traiter ces data et les perspectives qu'offrent leur traitement et leur visualisation a donné naissance à de nombreuses opportunités économiques et à un nouveau marché essentiellement composé de trois secteurs : les infrastructures (data centers), l'organisation et l'analyse (logiciels de traitement), et le service (business consulting). Ces secteurs économiques apparaissent comme des secteurs dynamiques, générant en 2020 plus de 5 milliards de revenus, et tout porte à croire que le secteur du Big Data continuera à s'accroître dans les prochaines années. La figure ci-dessous (fig. A) montre l'évolution de la quantité de données utilisée depuis 2010 en zettabytes (1 milliard de gigabytes), ainsi que la tendance prévue pour les quatre prochaines années.

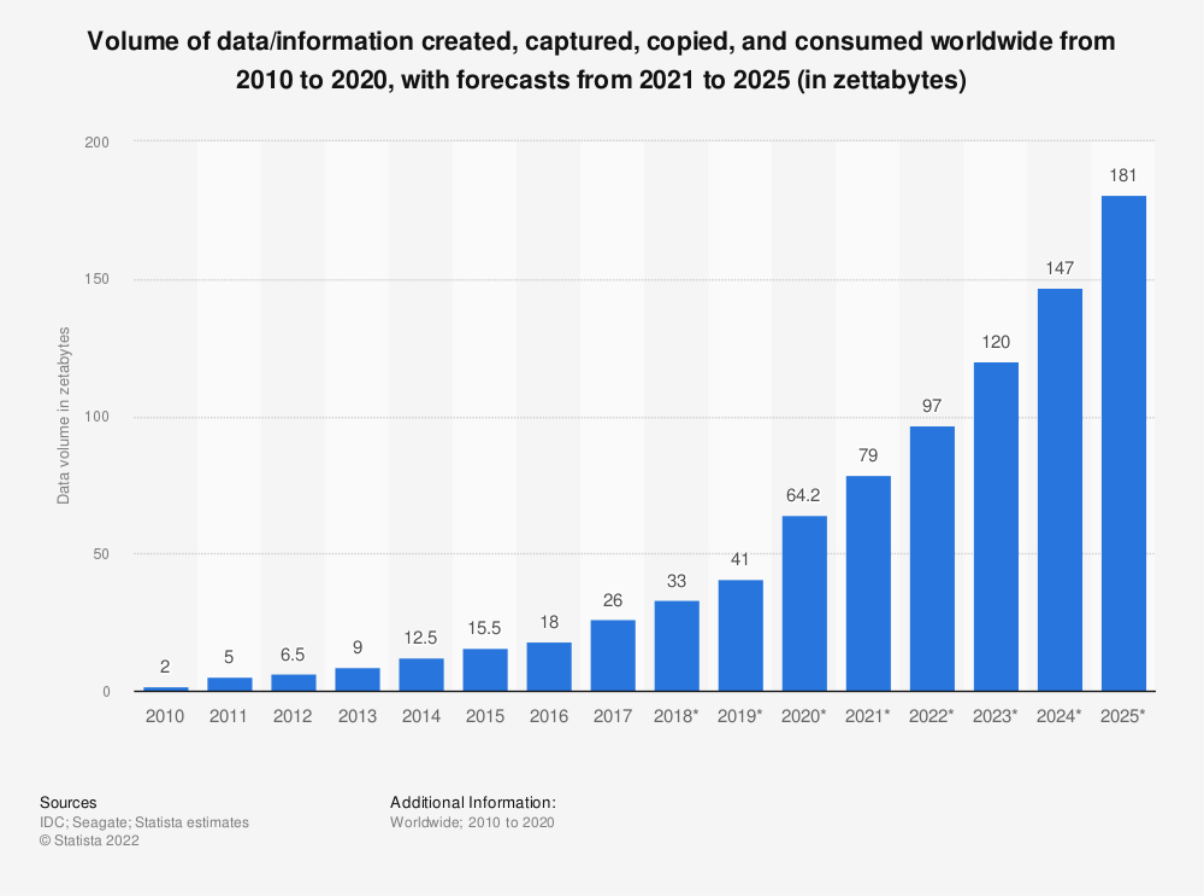


fig. A

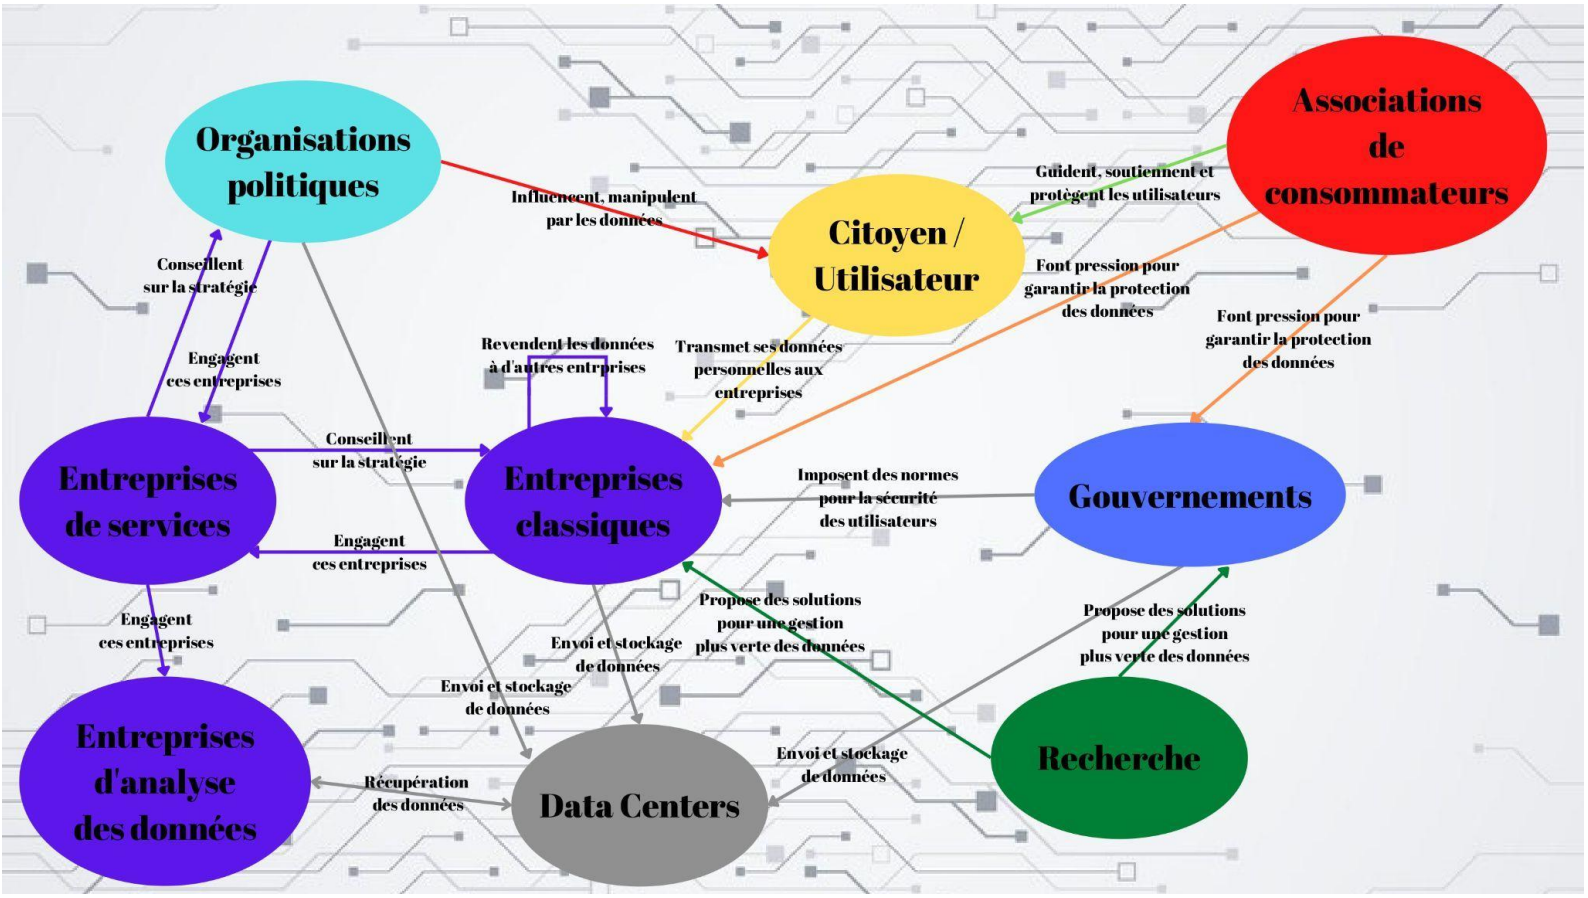
Le Big Data est donc un secteur économique très prometteur, il est également de plus en plus utilisé dans la recherche. Mais c'est aussi une technologie énergivore, qui demande la construction de Data Centers parfois très polluants, et ce, dans un contexte où il est

nécessaire de baisser la consommation. On peut se demander également quels sont les risques d'une telle technologie, lorsqu'elle est utilisée sur les données personnelles. Sans le cadre de la transition écologique et d'un effort commun de développement social, on peut se demander dans quelle mesure le Big Data peut transformer le monde vers un monde plus vert et plus juste socialement.

Dans ce rapport, nous tenterons de cerner les principaux liens entre le Big Data et les objectifs du développement durable, afin de déterminer dans quelle mesure le Big Data peut apporter des solutions aux problématiques de développement, d'écologie, mais également des enjeux sociaux. Nous tenterons d'évaluer les résultats de ces solutions et de leur efficacité. Nous exposerons également les risques liés à l'utilisation d'une telle technologie et les recherches en cours afin de les limiter.

CARTE DES ACTEURS

Voici donc une carte des acteurs qui explicite les différents acteurs liés au Big Data, ainsi que les relations qu'ils entretiennent entre eux.



I. Les problèmes soulevés par le Big Data

A. Les problèmes environnementaux du Big Data

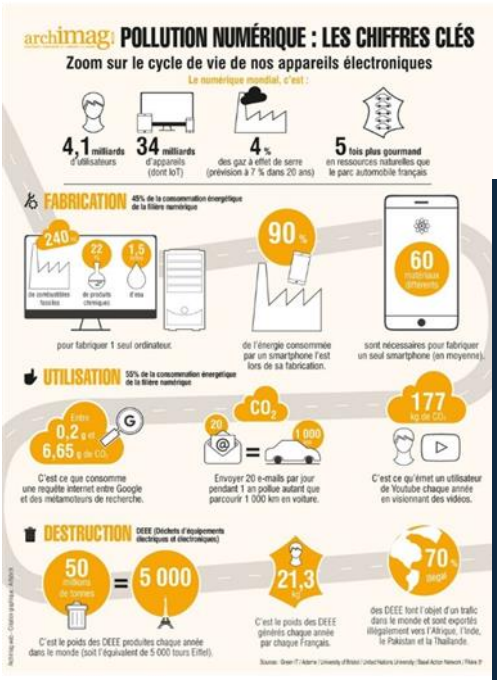
1. La pollution numérique : le fléau du XXIème siècle

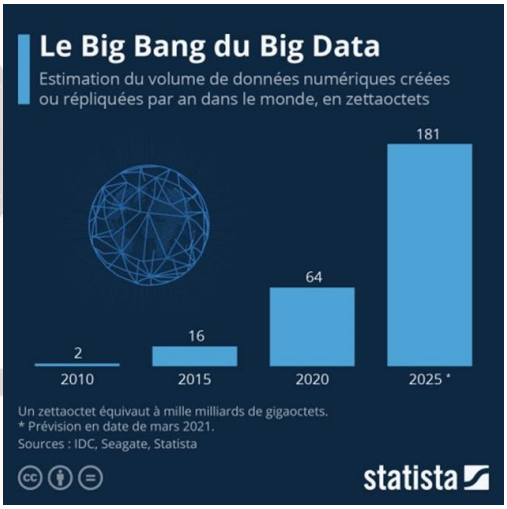
La pollution numérique est la pollution causée par le numérique, de la création des outils informatiques à l'utilisation de ces derniers. La pollution numérique est donc à la fois physique et virtuelle. Du fait notamment de la croissance du nombre d'équipements numériques dans les foyers, l'empreinte environnementale du Big Data ne cesse d'augmenter. Si les grosses entreprises comme Google ou Facebook participent largement à la pollution numérique, chacun est responsable de la pollution numérique. En effet le numérique repose principalement sur la data que consomme et produit les utilisateurs, ce qui prend en compte :

- Les milliards de vidéos enregistrés sur les différentes plateformes de streaming (Twitch / Youtube / Dailymotion…)

- Les milliards de messages et photos envoyés sur les réseaux sociaux (Facebook / Twitter / Instagram / LinkedIn…)

- Les milliards de recherche internet faites chaque jour par les utilisateurs





2. Le problème des data centers

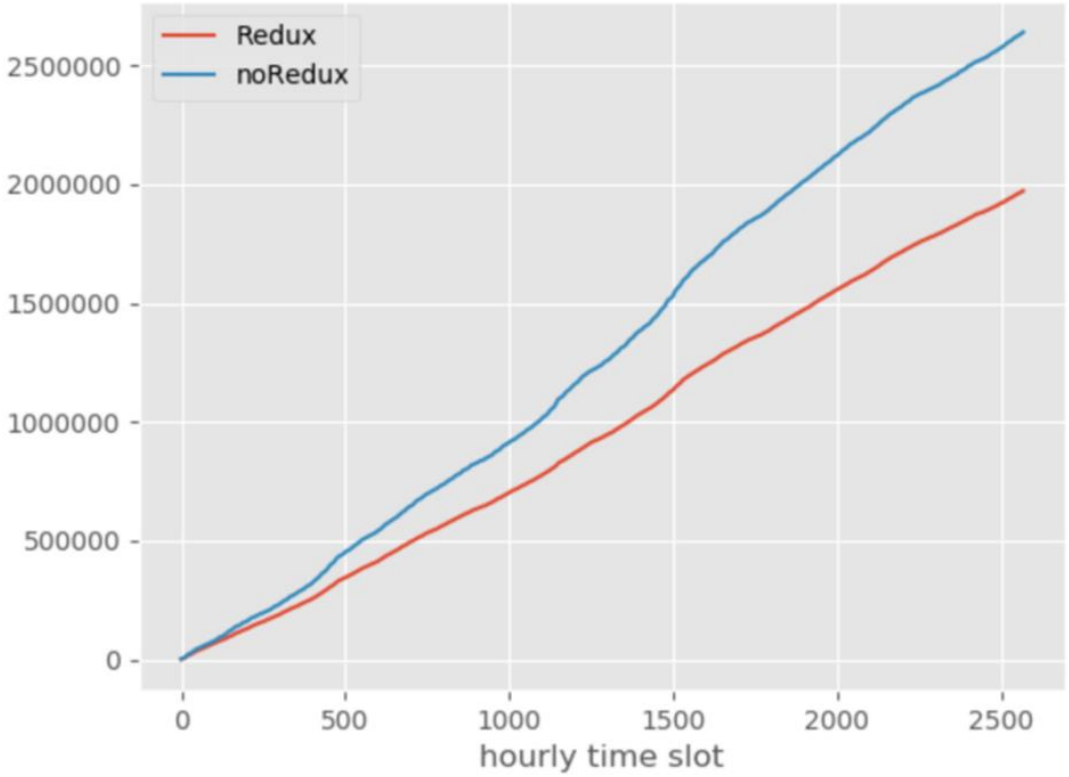


Les data centers sont indispensables dans nos vies de tous les jours. Ce sont les lieux où sont regroupés différents équipements informatiques, notamment les serveurs. Ce sont ces serveurs qui stockent les milliards d'informations provenant d'internet. Cependant, un problème persiste : la grosse consommation d'électricité de ces data centers qui fonctionnent sans interruption. Aujourd'hui, il existe un peu plus de 4000 data centers dans le monde, représentant à eux-seuls 4% de la consommation mondiale et 2% des émissions de gaz à effets de serre. Son empreinte carbone est donc comparable à celle du transport aérien. Et ce problème environnemental majeur ne risque pas d'être résolu à l'avenir. Les data centers risquent de doubler leur consommation d'énergie tous les cinq ans. D'ici 2040, le stockage des données pourrait représenter 14% des émissions de gaz à effets de serre mondial. Qu'est-ce qu'un data center ? Un data center, ou centre de données, est un site où sont regroupés des ordinateurs, des serveurs, des routeurs et autres installations informatiques. Il est au cœur du Big Data car regroupe toutes les bases de données d'internet. Cependant, il est problématique car il consomme beaucoup d'électricité. En effet, un data center doit constamment être alimenté en électricité pour fonctionner et être refroidi. Ce dernier doit être maintenu à une certaine température (environ 20 degrés). Or, les installations informatiques produisent énormément de chaleur et doivent donc être climatisées continuellement. Dès lors, la consommation électrique moyenne d'un data center est

d'environ 30MW, mais les plus gros data centers peuvent consommer jusqu'à 100 MW, ce qui est l'équivalent de la consommation d'une ville de 50 000 habitants. Ainsi, les data centers attirent de plus en plus l'attention. De plus, les data centers causent des problèmes par rapport à la biodiversité. En effet, ces derniers nécessitent un grand espace. S'installer dans un tel espace pourrait altérer l'écosystème local et mener par ailleurs à la réduction voire l'extinction de certaines espèces.

3. Des solutions pour réduire la pollution liée au Big Data ?

Initialement, les data centers étaient alimentés par des énergies fossiles. Mais depuis quelques années, il est évoqué la possibilité d'utiliser des énergies renouvelables pour respecter l'environnement. L'objectif d'ici 2025 est d'alimenter à 75% les data centers grâce à des énergies renouvelables et à 75% en 2030. De plus, il existe des solutions permettant de réduire la consommation énergétique sans perturber le bon fonctionnement d'un data center. C'est notamment le cas du système REDUX, un système unifié de gestion de l'efficacité énergétique. Ce système se démarque grâce à un dispositif d'alimentation sans interruption adapté aux énergies renouvelables comme le solaire et l'éolien. Le but de REDUX est d'économiser la facture d'électricité tout en gardant la performance des data centers. C'est une première avancée pour résoudre la consommation énergétique grandissante des centres de données. REDUX est capable de réguler la consommation en électricité et d'utiliser les avantages des énergies renouvelables qui peuvent rapidement augmenter leur capacité de production pour s'adapter aux besoins des data centers. Ce système ouvre la voie à des data centers modernes respectueux de l'environnement et amène un optimisme quant à la possibilité à l'avenir de réduire grandement la consommation des data centers qui sont des lieux très énergivores.



Evolution de la consommation d'énergie d'un data center (en kW/H) en fonction du temps avec et sans le système REDUX

Concernant le Big Data lui-même, il est aussi possible de réduire son empreinte carbone. Concernant la production, la collecte et la transmission des données, il s'agirait de supprimer ou compresser les données inutiles ou ayant peu d'importance. Concernant l'analyse des données, il faudrait rendre plus efficace, moins gourmande en énergie le traitement des données en métamorphosant l'architecture de traitement de données. Enfin, chacun peut participer à la réduction de la pollution numérique. Par exemple, il faudrait utiliser le WIFI plutôt que la 4G ou encore éviter de regarder toutes ses vidéos en HD.

4. Le Big Data : une réponse à la crise environnementale ?

Le changement climatique n'est pas exclusivement lié au Big Data, c'est un phénomène global causé par de nombreux facteurs. Les données ne sont qu'un des facteurs du changement climatique et de la consommation excessive d'énergie. Mais le Big Data peut être un moyen de faire face aux défis du changement climatique. Le Big Data peut par exemple avoir un rôle dans les chaînes d'approvisionnement, en aidant les entreprises à choisir le fournisseur à plus

faibles émissions de carbone à travers les données fournies par ces fournisseurs. De manière générale, la Big Data permet de mieux comprendre les défaillances liées aux nombreux produits numériques et par conséquent allonger la durée de vie de ces derniers, ce qui mènerait à une meilleure durée de vie des appareils numériques. Le Big Data aide également les entreprises à concevoir une stratégie durable, permet de surveiller la pollution de l'air et d'anticiper les catastrophes naturelles.

Un exemple de réussite est le projet asknamR de l'entreprise NamR. AsknamR est une plateforme de données française permettant d'évaluer les bâtiments sur notre territoire. Le projet a été récompensé en se voyant remettre le prix de l'innovation au salon Big Data & AI de Paris 2022. La plateforme a de nos jours étudié plus de 34 millions de bâtiments, ce qui permet de:

- Etudier l'évolution des risques climatiques pour les assureurs
- Préparer et planifier la transition écologique des territoires et collectivités
- Rendre compte des facteurs écologiques et environnementaux dans la recherche des terrains pour le développement immobilier
- Optimiser la rénovation énergétique et le développement de l'utilisation de l'énergie pour le secteur immobilier

Ce projet n'est qu'un exemple parmi tant d'autres. Le Big Data est une réelle solution et un outil pour aider à réduire le réchauffement climatique et à protéger l'environnement.

B. La question de l'éthique

Au-delà de la question environnementale traitée, celle de l'éthique semble également fondamentale pour traiter l'ensemble des changements et problèmes éventuels qu'apporte le Big Data au sein de nos sociétés. En effet, les enjeux éthiques recoupent à la fois les questions environnementales, sociales et sociétales, ce qui offre une vue d'ensemble sur la construction de nos sociétés autour de ce Big Data.

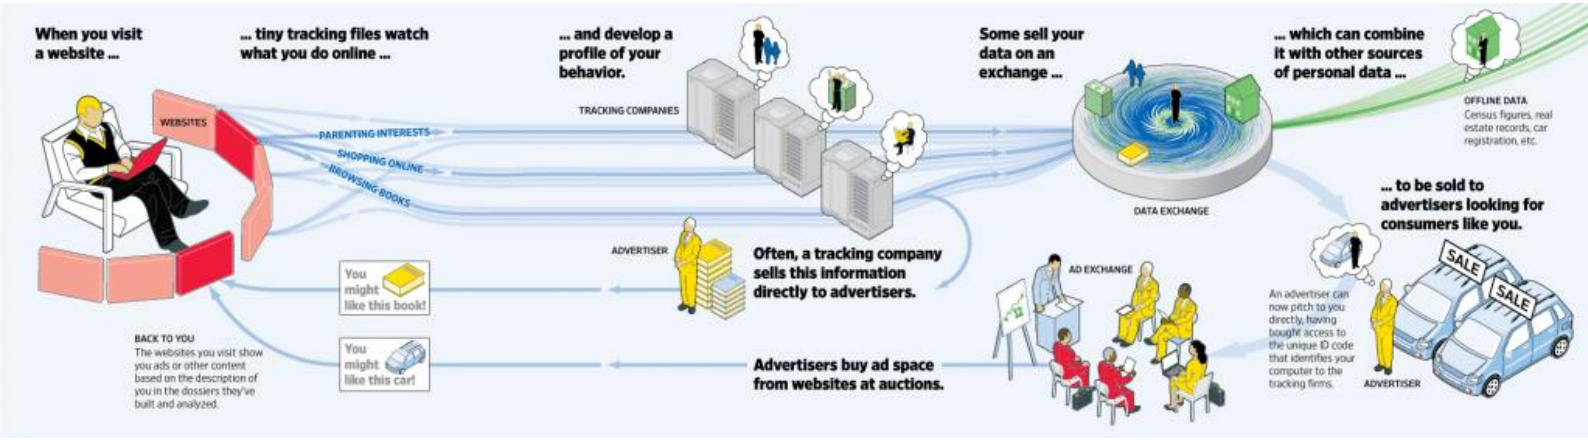
1. Quels problèmes de nature éthique le Big Data soulèvent-t-il ?

Tout d'abord, sur le plan politique, la question de l'utilisation des données est au cœur des débats modernes. Motif de discorde, de procès et autres controverses, l'utilisation des données privées à des fins politiques est fortement critiquée. En effet, ce type d'usage de la donnée privée des utilisateurs peut permettre aux figures politiques de créer des campagnes d'influence ciblées afin tout en manipulant les citoyens sans que ces derniers ne s'en rendent compte. Cette utilisation condamnable des données personnelles des utilisateurs à grande échelle s'est notamment illustrée dans le cas de la société de conseil Cambridge Analytica en 2018. En effet, cette année-là, à la suite d'un lancement d'alerte effectué par plusieurs de ses employés (dont Christopher Wylie notamment), la société a été accusé d'avoir, via la transmission de données utilisateurs Facebook d'avoir participé à une manipulation par le camp des Républicains de Donald Trump de l'électorat américain lors des élections présidentielles de 2016. Cette récolte de données via le réseau social aurait permis d'orienter les électeurs dans leurs décisions, en adaptant les discours du candidat aux publics ciblés lors des meetings, mais aussi à travers les suggestions de recherches internet soumises aux utilisateurs ciblés, qui mettaient en tête de page web des articles incriminant, dénigrant et décrédibilisant la candidate démocrate, Hillary Clinton. Cet exemple montre donc bien l'importance de la question éthique au sein de la sphère politique : jusqu'où peut-on et doit-on aller pour convaincre les électeurs ? Cette question qui divise ne demeure pas moins cruciale pour l'avenir de nos sociétés, de plus en plus assaillies par la donnée.

D'un point de vue social et sociétal, certains usages de la donnée peuvent également être controversés. En effet, si l'on s'intéresse aux stratégies de profilage par exemple (les plus

critiquées), il semble que la question de l'éthique soit une fois de plus au cœur du débat. Pour rappel, le profilage sociologique est une stratégie commerciale utilisée par beaucoup d'entreprises et autres organismes publics ou privés qui, à partir des données récoltées sur les individus via leur appareils et applications, créent un profil utilisateur/client potentiel afin de suggérer les produits, offre et promotions les plus adaptées au profil établi en question. Cela pose alors divers problèmes. Dans un premier temps, la question de la provenance des données récoltées par l'organisme en question peut être posée : qui a transmis les données en question et comment ont-elles été communiquées ? Souvent, ces dernières sont issues des réseaux sociaux (like, commentaires, abonnements…) qui ont finalement accès à nos centres d'intérêt. Elles peuvent également provenir de nos recherches internet avec le cas des cookies, qui bien souvent sont acceptés mécaniquement par les utilisateurs qui n'ont pas conscience de ce que ces derniers représentent. Pourtant, comme la CNIL le rappelle, les cookies sont de petits fichiers regroupant un certain nombre d'informations sur les interactions créées par un utilisateurs avec une page web ou un site web : identifiant client, contenu des paniers avant achat sur les sites marchands, localisation, traçage à des fins publicitaires… De plus, il convient aussi de distinguer cookie interne (émis par le site) et tiers (émis par un domaine extérieur). Ceci pose alors un réel problème vis-à-vis de la confidentialité des données privées des utilisateurs. Une fois obtenues par ces réseaux ou sites web, elles sont revendues aux plus intéressés afin de construire ces fameux profils qui, comme dans le cas de la sphère politique étudiée précédemment, permettront d'élaborer, notamment pour les entreprises, un ciblage, une communication et plus généralement une stratégie marketing plus efficace.

Schéma simplifié sur le fonctionnement des cookies



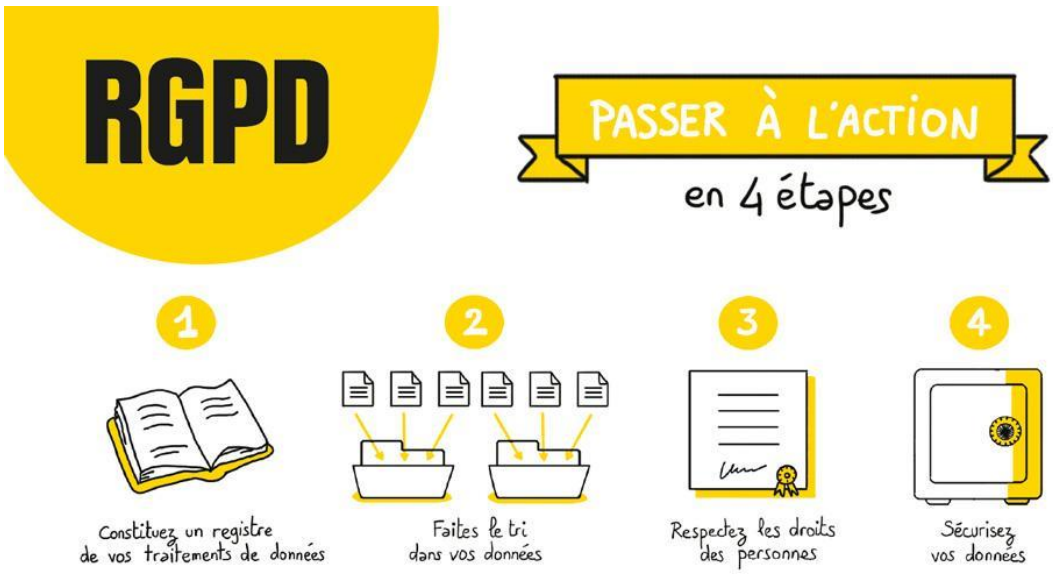
Cela remet alors clairement en cause le caractère privé de ces données. La large majorité des utilisateurs se font donc, sans le savoir, « voler » une partie de leur vie privée, qui est utilisée à des fins commerciales : la donnée devient un bien de consommation pour les entreprises.

Quelle réglementation sur la donnée ?

Face à l'ensemble des enjeux éthiques qui gravitent autour de la donnée, il convient alors de se poser la question sur les codes, normes et lois qui régissent la donnée. On peut en effet imaginer que le cadre légal peut permettre une sauvegarde et une sécurité des données privées des utilisateurs afin de maintenir la confidentialité de ces données personnelles.

Tout d'abord, la réglementation européenne la plus connue concernant la récolte et l'exploitation des données en Europe est le Règlement général sur la protection des données (RGPD). Entrée en vigueur en 2018, cette loi européenne a pour vocation première de préserver le droit à la vie privée des utilisateurs des différents réseaux au niveau européen en premier lieu, mais également par-delà les frontières de l'Union européenne. Dès lors, tout site destiné aux Européens doit se conformer au RGPD. Sur la question des cookies, le RGPD instaure de nouvelles règles relatives au consentement. Par exemple, le défilement de la page web par l'utilisateur qui surfe sur le site ne vaut pas (ou plus pour ceux qui appliquent cette

politique) consentement tacite de l'utilisateur, qui doit lui-même confirmer qu'il accepte les cookies dès son entrée sur la page web. De plus, c'est lui, et lui seul, qui doit « cocher » les cookies qu'il accepte (interdiction pour les sites de réaliser une pré-sélection de cookies que l'utilisateur accepte directement). Le but étant finalement de permettre à l'utilisateur d'avoir conscience des informations qu'il transmet, mais aussi et surtout de s'y intéresser. Le RGPD définit ensuite les différents cadres légaux dans lesquels les informations personnelles des utilisateurs peuvent être communiquées : consentement, contrat, assistance à personne en danger… de façon à garantir le caractère privé et confidentiel de ces données pour l'utilisateur.



Les ambitieux objectifs du RGPD

Toutefois, bien que le RGPD soit un progrès pour la considération de la confidentialité des informations transmises par les utilisateurs mais aussi pour la prise de conscience de la dimension éthique du Big Data, il n'a en réalité que peu d'influence sur la réalité et la

sauvegarde de l'intimité des utilisateurs. En effet, d'une part, dans la pratique, les utilisateurs ne lisent pas voire jamais les conditions d'utilisation des cookies et acceptent sans se soucier des conséquences de cet accord lesdites conditions. De plus, certains sites vont jusqu'à faire payer leurs utilisateurs s'ils souhaitent refuser les cookies sous peine d'impossibilité d'accès au site, ce qui constitue indéniablement un frein à la liberté de l'utilisateur, mais aussi à l'efficacité du RGPD. D'autre part, le RGPD reste une législation européenne et peine à s'imposer face à l'extraterritorialité du droit américain (Laïdi, 2021). Ce concept, définit littéralement la capacité du droit américain à s'exercer en dehors de ses frontières par le biais des entreprises américaines, des réseaux gérés par les Etats-Unis ou même s'il y a transaction en dollar américain dans certains, qui représente, rappelons-le, la monnaie utilisée majoritairement pour les échanges commerciaux. Le droit américain envahit dès lors toutes les sociétés ouvertes sur la mondialisation. Dans le cas du Big Data, le *CLOUD Act* (Clarifying Lawful Overseas of Data Act) montre les limites des normes européennes face à l'omniprésence américaine. Cette loi américaine dispose effectivement que toute entreprise américaine doit donner libre accès aux données qu'elle dispose aux juridictions américaines, ce qui va clairement à l'encontre du RGPD.

On voit donc bien les limites du modèle classique de réglementation par les Etats, qui entrent eux-mêmes en compétition les uns avec les autres, dans la construction d'une éthique pour le Big Data.

1. Comment construire la dimension éthique du Big Data ?

Sur le plan philosophique, il convient dans un premier temps de rappeler certains concepts et définitions qui permettront d'appréhender la problématique de l'éthique. Il faut effectivement distinguer trois posture éthiques différentes :

- La déontologie kantienne de l'impératif catégorique (Pascal, 1785) :

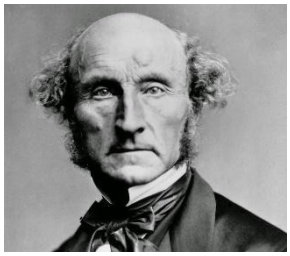
« Agis uniquement d'après la maxime qui fait que tu peux vouloir que tu puisses vouloir en même temps qu'elle devienne une loi universelle. » Tel est énoncée la règle de



E. Kant (1724-1804)

conduite kantienne, rationnelle elle promeut une doctrine qui se veut universelle pour le bien-être de tous et le bon vivre ensemble.

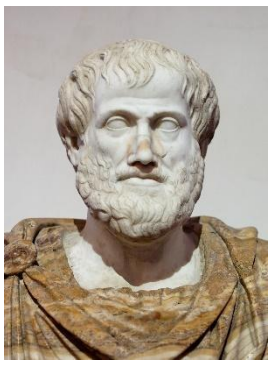
- <u>Le conséquentialisme utilitariste (Mills, 1961) :</u>



J. S. Mill (1806-1873)

Cette éthique se fonde avant tout sur les conséquences des actions produite. Une « action souhaitable » est donc une action qui possède des conséquences positives pour le plus grand nombre, ou du moins plus d'externalités positives que négatives.

- <u>L'éthique des vertus (Aristote, IVe siècle av. J.-C.) :</u>



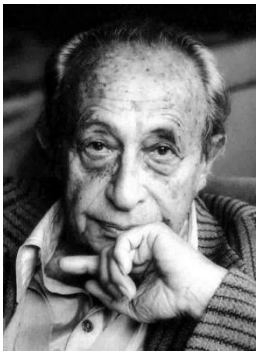
Aristote (384-322 av. J.-C.)

Cette dernière éthique se concentre, contrairement aux deux premières à caractère universel, sur l'individu, son parcours, ses valeurs personnelles. Elle réside donc dans l'accomplissement de soi, selon ses propres valeurs. Un « action souhaitable » est donc une action qui est en accord avec le dévoilement des vertus personnelles.

Lorsque l'on en vient à évoquer le Big Data, il faut alors distinguer différents types de données pour tenter de leur trouver une éthique adéquate. En effet, on pourrait considérer que ce qui relève de la dimension personnelle et individuelle, les données doivent être soumises à une éthique des vertus, du côté des utilisateurs (liberté de donner ou non leurs données en fonction des sites, réseaux, applications…) et des organismes qui les récoltent (charte déontologique des entreprises qui sont en réalité l'exposé des vertus des entreprises). Néanmoins, face à cela des interdits doivent demeurer pour préserver les utilisateurs souvent mal informés sur l'utilisation de leurs données et c'est en ce sens que l'impératif kantien

pourrait s'imposer au travers de plus de lois réglementant le traitement et le partage des données afin de mieux respecter la vie privée des utilisateurs.

Concernant les données qui dont l'exploitation pourrait servir au plus grand nombre (test pour l'efficience énergétique des appareils par exemple), une forme de conséquentialisme pourrait s'appliquer. Néanmoins, des réticences nombreuses seraient sûrement attendues dans le cas d'un tel virage dans l'utilisation des données. En effet, tout individu qui se verrait prélever ses données pour le « bien sociétal » pourrait contester l'apport personnel qui tirerait de ce « sacrifice », et par conséquent refuser de transmettre ses données. Néanmoins, comme une cotisation, on pourrait imaginer un impôt numérique sur des données ne relevant pas du confidentiel de la vie des utilisateurs ou des entreprises, qui serait utilisé dans le but unique d'améliorer le quotidien des sociétés.


H. Jonas (1903 – 1993)

Enfin, une autre éthique développée par Jonas (1979) recoupant à la fois les enjeux environnementaux et sociaux susmentionnés serait l'impératif écologique, le principe responsabilité, qui inciterait tout le secteur du Big Data à se développer en préservant l'environnement et les générations futures. Cela semble d'autant plus pertinent que cette sphère de la donnée va être amenée à se développer de plus en plus (intelligence artificielle, ville intelligentes) et s'adresse ainsi nécessairement aux générations futures. Cependant, un problème majeur demeure : celui de l'harmonisation des politiques gouvernementales. En effet, comment serait-il possible d'appliquer un quelconque impératif qui se veut universel si les Etats n'organisent pas leurs lignes de conduite ? C'est en ce sens qu'une éthique multiple (en fonction des données) est théoriquement possible mais sa mise en place demeure, elle, peu probable du fait de cette discorde entre Etats. A cela s'ajoutent également les grandes entreprises détentrices de données qui servent pour la plupart leurs intérêts actuels, de plus en plus puissantes politiquement, et ne verront donc aucun intérêt particulier à accueillir un tel régime de réglementations à bras ouverts.

C. Un Big Data qui pourrait représenter un danger pour nos démocraties

1. La maîtrise du Big Data est au cœur des stratégies de puissances dites « révisionnistes », qui s'opposent à nos démocraties, et qui en font l'axe majeur de leur montée en puissance

La maîtrise du Big Data, de données universelles concernant un nombre important de la population, offre en effet de nombreux avantages aux gouvernements qui les contrôlent : un pouvoir sans précédent sur la population, que ce soit la population interne au pays ou bien une population qui vit au-delà des frontières de celui-ci. Et c'est sur ce point-là que certaines puissances révisionnistes, qui veulent réviser l'ordre occidentalo-centré tel qu'il est aujourd'hui. On peut par exemple prendre l'exemple de la Russie, qui met véritablement la maîtrise du Big Data au cœur de sa stratégie. Elle s'affiche comme une puissance en pointe de la guerre de l'information que se livrent aujourd'hui les grandes puissances, guerre qui tourne autour du contrôle des données. La Russie dispose ainsi d'un véritable « sharp power » (Christopher Walker et Jessica Ludwig), qu'on peut définir comme un pouvoir reposant sur « la subversion, l'intimidation et les pressions exercées par des régimes autoritaires sur des démocraties ». Ce sharp power passe notamment par « l'usage trompeur d'informations à des fins hostiles ». Ainsi, un contrôle du Big Data par Moscou lui permet d'intervenir dans de nombreux domaines, comme par exemple lors des élections présidentielles de 2016 où l'ingérence russe semble avoir joué un rôle non négligeable dans l'élection de Donald Trump. La guerre de l'information a également joué un rôle crucial dans le conflit syrien afin de faire mentir les discours occidentaux par le biais de la production de fausses images ou de faux reportages. Cette maîtrise de la Data joue également un rôle important dans le conflit ukrainien actuel, qui se caractérise notamment en tant que guerre hybride avec une importance du Big Data. Mais la Russie n'est pas la seule à se servir du Big Data pour contrer les démocraties occidentales. C'est notamment ce que fait largement la Chine de Xi Jinping. Elle agit pour cela à deux niveaux. Tout d'abord, elle souhaite préserver ses données au sein de son territoire : il est aujourd'hui bien difficile d'avoir accès aux données des habitants chinois. La Chine a en effet développé son propre internet, qui s'est développé derrière ce que les autorités chinoises appellent le « Bouclier Doré », ou encore la « Grande Barrière Numérique », immense firewall protégeant les données chinoises. Ce contrôle total du Big

Data permet aux autorités de faire se développer à l'abri de la concurrence leurs champions nationaux, les BATHX (Baidu, Alibaba, Tencent, Huawei et Xiaomi). Cela leur permet également d'avoir à une immense base de données, permettant ainsi aux BATHX de se perfectionner au mieux pour pouvoir ensuite aller concurrencer les entreprises occidentales, notamment les américaines GAFAM (Google, Apple, Facebook, Amazon et Microsoft). Ainsi le contrôle du Big Data permet des avantages internes. Mais il présente également des avantages au-delà des frontières chinoises : fragiliser le monde occidentalo-centré établi pour trouver sa place dans un nouvel ordre mondial. Et cela se fait notamment par la maîtrise du Big Data. Pékin a en effet largement agi selon la devise « diviser pour régner », comme l'illustre les accords bilatéraux qu'elle a conclus avec différents pays européens. Elle implante notamment sa technologie en Europe, grâce à sa performante 5G développée via Huawei. Cette 5G pourrait lui permettre, entre autres, de pouvoir récolter de nouvelles données, différentes de celles qu'elle possède déjà grâce à l'immense base de données que représente la population chinoise. Pékin mise ainsi sur une maîtrise encore plus élargie du Big Data pour ainsi se positionner face aux États-Unis, en tant que chef de file d'un nouvel ordre mondial ou l'Occident ne serait plus au centre.

2. Le Big Data représente un danger pour les démocraties européennes

Aujourd'hui, l'Europe est en effet en retard en matière de contrôle et utilisation du Big Data. Face aux géants américains, les GAFAM et nouvellement les NATU (Netflix, AirBnB, Tesla et Uber) et aux géants chinois les BATHX, qui savent exploiter le Big Data, l'Europe semble à la traîne. Elle ne dispose pas de champion permettant de concurrencer ses rivaux, qu'ils soient Américains ou Chinois. Comme l'expliquait Jacques Lesourne, « la supériorité technique qui, par deux fois, lors de la Renaissance puis dans la période des Lumières, a permis l'essor mondial de la civilisation européenne est en train de disparaître ». L'Europe ne s'est pas imposée dans les industries de la « 3ème Révolution Industrielle » (Jeremy Rifkin), celles des NTIC, et surtout ni dans celles de la « 4ème Révolution Industrielle » (Klaus Schwab), celle de la data. Cette faiblesse s'explique notamment par la fragmentation du marché européen, qui représente un obstacle aux effets d'échelle, en particulier au niveau de la collecte de données. D'autre part, l'Europe est en retard dans la maîtrise des infrastructures au fondement de ces

révolutions technologiques en cours, ce qui la rend vulnérable, notamment à l'espionnage américain, comme l'a révélé Edward Snowden en 2013. Il faut d'ailleurs noter qu'il n'existe pas de véritable cloud européen capable de stocker le Big Data européenne. Une grande partie des données européennes sont soit hébergées aux États-Unis, soit contrôlées par des géants américains de l'internet, tels que Amazon Web Services, Microsoft Azur ou encore Google Cloud.

Par ailleurs, une des révolutions majeures en termes de data est actuellement la 5G. Et les leaders européens Nokia et Ericsson peinent à faire le poids face à la chinoise Huawei. Or la 5G constitue une infrastructure décisive de la « 4ème Révolution Industrielle », celle du Big Data. En effet, elle touche de nombreux domaines tels que les usines connectées, l'intelligence artificielle, les voitures autonomes, la santé ou encore les objets connectés. Et si Huawei mène en Europe une stratégie de séduction, les États-Unis ont déjà interdit aux entreprises américaines de collaborer avec le géant de la tech chinois, et font pression sur les alliés pour qu'ils fassent de même (le Japon a déjà banni Huawei de ses infrastructures par exemple). Cependant, ceci a pour conséquence paradoxale de permettre à la technologie chinoise de devenir plus performante. En effet, elles sont obligées de se développer sans soutien des entreprises américaines leaders du secteur, donc deviennent leaders en Chine de manière autonome et sont aujourd'hui indépendantes. Cela contribue à créer deux blocs géopolitiques fondés sur des écosystèmes technologiques distincts. Or l'Europe se retrouve en quelque sorte coincée entre les deux. Il faut donc qu'elle innove dans le secteur du Big Data si elle ne veut pas se retrouver subsidiaire face à deux nouveaux géants qui maîtrisent et savent utiliser cette technologie. Cela est donc un enjeu majeur pour l'avenir des pays européens.

3. L'omniprésence du Big Data semble indiquer que nous sommes entrés dans « l'âge du capitalisme de surveillance » (Shoshana Zuboff)

Ce Big Data constitue en effet un important défi pour les démocraties. Comme l'explique Shoshana Zuboff dans *L'âge du capitalisme de surveillance*, l'utilisation excessive du Big Data conduit à un développement de plus en plus important des techniques de surveillance par les États démocratiques, que ces derniers légitiment pour des raisons sécuritaires (lutte contre

les flux illicites, ou encore contre le terrorisme). Ce Big Data accorde même un pouvoir inédit à certains gouvernements de régimes autoritaires. On peut par exemple prendre l'exemple de la Chine et de son fameux crédit social. Actuellement, Pékin étend à l'ensemble de sa population un système de notation de ses citoyens. L'objectif est d'utiliser à terme la très grande quantité de données collectées sur les 900 millions utilisateurs de l'internet chinois, à l'aide de 200 millions de caméras intelligentes à reconnaissance faciale qui sont placées partout dans le pays, mais également les données fournies par les banques ou encore les opérateurs de télécommunication. Cela permet d'analyser les habitudes de consommation, ou encore les avis de la population sur le Parti Communiste Chinois, et de leur attribuer une note, allant de D (pour le mauvais citoyen) à A (pour le bon citoyen). Et en fonction de leur note, les citoyens se voient accorder des avantages (tickets de métro moins chers, accord plus facile de prêts bancaires) tandis que ceux avec une mauvaise note se voient attribuer des sanctions (interdiction de crédit bancaire, sonnerie de téléphone spécifique pour qu'on les reconnaisse dans les lieux publics…). Loin d'être une dystopie orwellienne, on peut dire que nous sommes entrés dans « l'âge du capitalisme de surveillance », qui risque de mettre en déroute nos démocraties et les valeurs qu'elles portent si l'usage du Big Data n'est pas réglementé.

Il faut par ailleurs noter que ce capitalisme de surveillance est également le fait d'acteurs privés, et notamment des géants du numérique. Ces derniers ont effectivement fondé leur réussite sur la maîtrise du Big Data, et elles en possèdent des masses considérables de données extrêmement précises sur leurs utilisateurs. Ces données peuvent d'ailleurs être utilisées à des fins politiques. C'est notamment ce qu'avait montré le scandale Cambridge Analytica : cette entreprise anglaise avait utilisé les données personnelles de 87 millions d'utilisateurs Facebook pour orienter le vote de certains électeurs américains lors des élections présidentielles de 2016.

Ainsi, l'omniprésence des données numériques, et le contrôle de ces dernières par différents acteurs (gouvernements, entreprises privées) pose aujourd'hui de nombreux problèmes qu'il s'agit de résoudre. Ainsi faut-il donner moins de données aux géants du numériques, mais ce qui les rendrait de facto moins performants ? Faut-il placer certaines limites à la maîtrise et au contrôle de nos données personnelles ? Et si oui, où placer la limite ? Et qui doit placer la limite ? Et pour autant, faut-il réellement placer une limite ? Le Big Data ne permettrait-elle

pas, entre autres, de simplifier notre vie pour atteindre un niveau de confort jamais égalé ? Peut-on être gagnant avec une telle utilisation du Big Data ? Toutes ces questions demeurent aujourd'hui épineuses. Pour autant, il ne faut pas négliger le fait que même si elle comporte des aspects qui peuvent apparaître obscurs, le Big Data nous apporte incontestablement beaucoup au quotidien.

II. Les apports au quotidien du Big Data

A. Les apports du Big Data dans le sport

Il y a deux types d'analyse dans l'industrie du sport que l'on peut nommer "sport analytics" et "business analytics". La première concerne l'analyse de données comme augmentation de la performance tandis que la deuxième a un rapport avec le côté

1. Le sport n'a pas échappé à l' « ère du Big Data »

À l'échelle mondiale, le marché du sport à un niveau professionnel représente plus de 90 milliards d'euros. Par conséquent, tous les sports, qu'ils soient individuels ou collectifs, se retrouvent à analyser de nombreuses données afin d'améliorer les performances. Aux origines de cette utilisation massive des données, on retrouve l'équipe américaine de baseball, les Oakland Athletics, au début des années 2000. Dans son livre intitulé *Moneyball*, Michael Lewis relate l'épopée de 2002 de cette équipe qui deviendra une des meilleures de la saison grâce à l'utilisation du Big Data, notamment dans le recrutement de l'équipe. Cette équipe d'Oakland venait de perdre ses meilleurs joueurs. Disposant d'un petit budget comparé aux autres équipes de la ligue, Billy Beane, manager de l'époque, eut une idée révolutionnaire. Pour recruter les nouveaux joueurs de son équipe, Mr Beane et ses assistants ont mis au point un algorithme permettant de trouver des joueurs méconnus ou délaissés par les autres équipes. L'analyse précise des données récoltées sur chaque joueur a permis aux Oakland Athletics de recruter des joueurs convenant parfaitement au collectif. Chacun avait un rôle précis à jouer dans l'équipe. Si les résultats n'ont pas suivi au début de la saison, l'équipe finira la saison par battre le record de victoires de la ligue. Dès la saison d'après, toutes les équipes de la ligue décidèrent d'adopter la même méthode d'analyse de données. Depuis, toutes les autres disciplines ont suivi et le sport est entré dans une nouvelle ère : l'ère du Big Data. Même un sportif occasionnel voit sa pratique sportive évoluer grâce au Big Data. C'est notamment le cas du pratiquant de la course à pied. Que ce soit avec une montre connectée ou un smartphone, les coureurs à pied peuvent désormais avoir accès à une très grande quantité de données sur leur exercice. Durée de l'exercice, nombre de kilomètres parcourus, vitesse moyenne, rythme cardiaque font partie des données auxquelles

l'utilisateur peut avoir accès. Toutefois, le fait que le sport entre dans l'ère du Big Data n'apporte pas que du positif. Les problèmes liés au Big Data se retrouvent également dans le sport, notamment par rapport aux données personnelles. En effet, l'utilisateur n'est pas le seul à avoir accès à ces données. Prenons l'exemple de Runtastic, une application rachetée par Adidas. Voici une liste d'entreprises ayant accès à nos données sur l'application :

- Facebook
- Google
- Adjust : société de marketing mobile spécialisée dans la publicité
- Emarsys : société de data marketing permettant à Runtastic de vous profiler

On peut donc en déduire que les données récoltées sur les applications liées au sport intéressent fortement les entreprises qui enrichissent leur base de données déjà conséquente. De plus, il est possible de partager ses parcours sur ces applications. Si l'intention de partager son exercice ne pose aucun problème en soit, elle peut mettre en danger la personne. Une personne malintentionnée peut avoir accès aux parcours des coureurs et il y a malheureusement eu des agressions à cause de ces applications : une personne faisant tout le temps le même parcours peut devenir une victime facile.

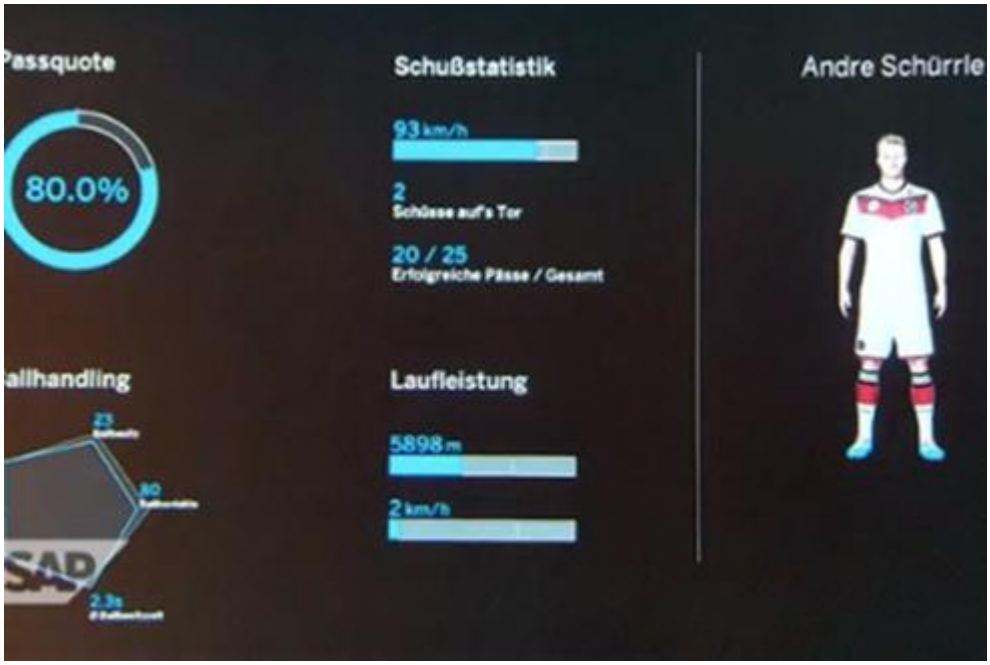
2. Le Big Data : une réelle plus-value pour le sport grâce au "sport analytics"

Il est possible de trier les différentes plus-values du "sport analytics" en quatre catégories :

- Le recrutement
- La tactique
- L'amélioration des entraînements
- La prévention de blessures

Les deux premiers apports du Big Data sont possibles grâce à la récupération de données fournies par des entreprises spécialisées comme Opta. Les ligues et les clubs ont des partenariats avec ces entreprises afin d'obtenir à leur guise de nombreuses données. Nous

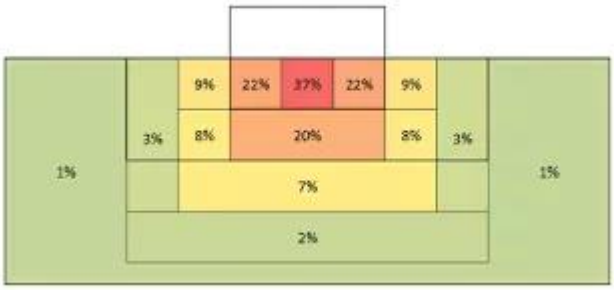
avons vu à travers l'exemple des Athletics Oakland que les équipes recrutent leurs joueurs de plus en plus grâce à une analyse poussée de la data. Mais il est aussi possible d'optimiser la performance. Comment minimiser l'effort pour telle performance ? Quelles sont les points forts et les points faibles de tel sportif ou de telle équipe ? Voici des questions auxquelles seule le Big Data est en mesure de nous apporter une réponse. Le Big Data permet de connaître les points forts et les points faibles de son équipe et de l'équipe adverse, ce qui permet de créer une tactique en match. Par exemple, le Big Data a aidé l'Allemagne a gagné la coupe du monde de football en 2014. En effet, l'Allemagne avait lors de cette compétition un accord avec SAP, une entreprise informatique allemande. Cette dernière fournissait à la Mannschaft un outil d'exploitation et de visualisation des données révolutionnaire, permettant d'analyser les joueurs allemands mais aussi leur adversaire.



Capture d'écran du logiciel de SAP 1

Le Big Data est également un moyen de mieux comprendre une expérience sportive. Au football, il existe une donnée nommée « Expected goals ». Cette donnée correspond à la probabilité de marquer un but à chaque tir effectué par une équipe. Pour calculer cette probabilité, les fournisseurs de statistiques, Opta étant le plus gros fournisseur, ont analysé des milliers de tirs tentés dans l'histoire puis se basent sur une multitude de facteurs : comment a été marqué le but ? A quelle distance ? Quel était l'angle par rapport au but ?

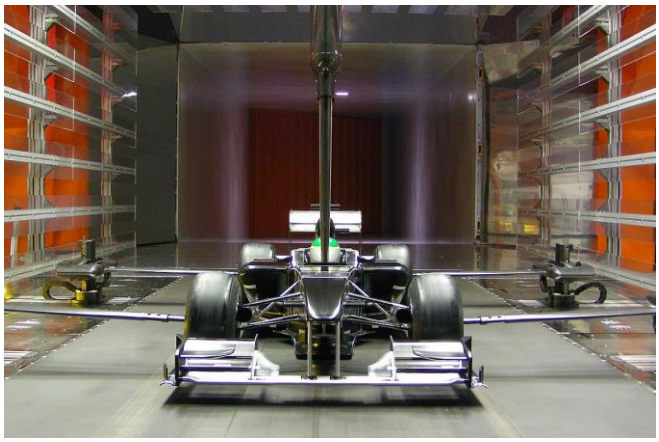
Cette statistique est désormais à la mode, notamment pour les consultants qui utilisent cette statistique pour justifier la domination d'une équipe. Toutefois, le football n'est pas qu'une question de probabilité et il n'est pas rare qu'une équipe avec beaucoup d'expected goals perde le match. Dès lors, la vérité du terrain l'emporte souvent sur la vérité des statistiques.



Cette image montre que la probabilité de marquer un but n'est pas la même en fonction de la position du joueur au moment de la frappe.

Les données provenant des deux dernières catégories que sont la gestion des blessures et la performance et l'amélioration aux entraînements sont issues des multiples données que possèdent directement une franchise sportive. Tous les sportifs de haut niveau sont désormais équipés de différents capteurs. Dès lors, les entraîneurs de ces équipes sont conscients chaque seconde de l'état de fatigue de leurs protégés. Le Big Data est donc non seulement un moyen de booster la performance sportive en optimisant chaque détail mais aussi un moyen d'éviter une blessure. Pour autant, il existe des sports où le Big Data est indispensable. C'est notamment le cas de la formule 1. Sport de plus en plus médiatisé, la Formule 1 offre à ses spectateurs un championnat constructeur et un championnat pilote dans lesquels vingt voitures lancées à plus de 300 km/h se battent sur la piste. Chaque milliseconde est importante en Formule 1. Par conséquent, il est essentiel pour toutes les écuries de réunir le plus d'informations possibles. Chaque seconde, à chaque tour, plus de 150 000 mesures sont effectuées par l'ordinateur de bord d'une voiture de f1, avec l'aide de plus de 200 capteurs directement intégrés sur la voiture. Vitesse du véhicule, température des moteurs, freins et pneus, forces g exercées sur le pilote : voici différents capteurs qui peuvent être utilisés pendant les courses. Mais le Big Data en Formule 1 est également essentiel avant même le début de la saison. En effet, le passage par la soufflerie est

nécessaire. C'est dans cet endroit que les premières données sont récoltées. Mais qu'est-ce que la soufflerie ? C'est un outil destiné à étudier les effets de l'air circulant autour d'un objet fixe. Elle consiste en un tube circulaire dans lequel circule de l'air en mouvement. A l'intérieur, les ingénieurs ont reproduit à l'identique la voiture à plus petite échelle. Le modèle réduit est alors placé dans la chambre d'essais de la soufflerie, sur un tapis roulant qui simulera la piste d'un grand prix. Le but de la soufflerie est de tester l'aérodynamisme de la voiture, qui est un des plus grands facteurs de réussite pour les écuries et voitures de F1, en simulant les conditions de vent que l'on pourrait retrouver sur la piste. Ces essais coûtent extrêmement cher aux écuries de F1, en plus de consommer beaucoup d'énergie. Dès lors, la Fédération Internationale de l'Automobile (FIA) a imposé des limitations quant à l'utilisation de la soufflerie. Toutefois, malgré toutes ces simulations, la voiture en conditions réelles ne réagira pas tout le temps comme elle le devrait. C'est pour cela par exemple que l'écurie Mercedes, une des plus grandes écuries de F1, a eu de nombreux problèmes sur sa voiture lors de la saison 2022.



Exemple de soufflerie en Formule 1

3. "Business Analytics": le deuxième type d'analyse dans l'industrie du sport

Le sport professionnel demande aux clubs et franchises sportives de posséder un budget plutôt conséquent. C'est donc pour cela que celles-ci se préoccupent de leur performance en tant qu'entreprise et qu'un deuxième type d'analyse dans l'industrie du sport nommé "Business Analytics" existe. La billetterie par exemple est une recette primordiale pour

certains clubs. Par exemple, en Major League Baseball (MLB), les équipes jouent 81 matchs à domicile en moins de 60 semaines. Difficile donc de remplir les stades gigantesques à chaque match. C'est pour cela que la tarification dynamique est apparue grâce à l'analyse des données. A l'aide d'un algorithme qui prend en compte différents facteurs comme la météo, la forme actuelle de l'équipe ou encore le jour du match, il est possible d'identifier le "prix parfait" d'un ticket pour allier bénéfice et stade rempli. Les franchises sportives se servent également de l'analyse des données pour identifier le retour sur investissement de leur sponsor. Ils sont capables de savoir préciser le pourcentage de fans sensibles à leurs sponsors, ce qui est utile lorsqu'il s'agit de renouveler un contrat. Il est aussi plus facile désormais pour les clubs d'attirer de plus en plus de fans ou du moins de garder leurs fans à travers des newsletter, des jeux concours, etc. Les profils des fans sont mieux ciblés, par conséquent les fans sont mieux compris. Grâce à l'analyse des données, l'expérience du spectateur et du téléspectateur ne cesse de s'améliorer. Par exemple, Canal + a instauré un "mode expert" sur leur application MyCanal. C'est un moyen pour les téléspectateurs d'être au plus proche de la course ou du matchs grâce à des statistiques et informations en temps réel, tout en continuant à regarder le programme sportif. Ce mode expert est pour l'instant disponible sur les matchs de football et de rugby, sur les courses de Formule 1 et de Moto GP ainsi que sur le Golf.



Le mode expert de MyCanal: une nouvelle expérience pour les téléspectateurs

Concernant les ligues sportives comme la Ligue Football Professionnel, la FIA, la NBA, etc, le Big Data est très importante du côté du marketing. Ces dernières utilisent les données recueillies sur les différents forums et réseaux sociaux afin d'examiner les différents avis des

fans. Par exemple, Max Metral, ancien insight Manager en Formule 1, nous a confié travailler grâce à l'analyse de données sur l'heure optimale d'un départ de grand prix pour satisfaire le plus de fans possibles dans le monde.

4. L'émergence du Big data condamne-t-elle l'instinct et le plaisir sportif ?

Le Big Data a apporté énormément de choses au sport et l'a transformé comme nous l'avons vu précédemment. Toutefois, ne pourrait-on pas affirmer que l'analyse constante des données entraîne la fin de l'instinct du sportif ? Ce dernier tend à ne plus prendre certains risques du fait de l'analyse des données qui contredirait le choix du sportif. C'est notamment une problématique récurrente dans le cyclisme. Introduite sur le Tour de France 1990, les oreillettes font désormais partie de l'équipement de tout cycliste professionnel. Mais son utilisation a grandement évolué depuis plus de 30 ans. Initialement, les oreillettes permettaient seulement au directeur sportif de l'équipe d'informer ses coureurs de l'évolution de la course et facilitent la remontée d'un peloton. Mais, depuis quelques années, ces oreillettes sont remises en cause et l'avènement du Big Data dans le sport est en partie une cause de cette remise en question. Désormais, les oreillettes sont moins un outil de sécurité qu'un moyen de parvenir à la stratégie d'une équipe. En effet, l'instinct sportif est de moins en moins présent dans ce sport, comme le montrait le cycliste Romain Bardet dans une interview. « C'est le vélo à l'instinct, rien n'était prémédité. Avant la descente, Mika (Chérel) m'a dit « Suis-moi, on peut faire un gros coup », j'ai répondu « T'es mes yeux je prends ta roue je te fais confiance » « même si on nous disait le contraire dans l'oreillette ». Avec toutes les données analysées par les équipes, les directeurs de course sont capables d'affirmer si une attaque va réussir ou non, de donner la probabilité de victoire d'un coureur. Et c'est particulièrement cela qui condamne l'instinct du sportif ainsi que l'intérêt du téléspectateur. Le cycliste n'est plus libre d'attaquer quand bon lui semble, comme le montrait le cycliste français Lilian Calmejane dans une interview en 2018. « Je ne sais pas pourquoi j'ai fait ça, je cours à l'instinct. Je me suis fait engueuler dans les oreillettes, du coup je les ai enlevées ». Il a ajouté « J'aime faire des efforts solitaires », « Je me fais plaisir chez les pros », « C'est comme ça que je conçois le vélo ». L'omniprésence des données et statistiques déshumanisent-elles le sport ? On aime le sport car il nous procure des émotions. Or les statistiques, les données

semblent réduire excessivement le suspens d'une rencontre. Où est le suspens quand les statistiques donnent une probabilité de 2% à une équipe de baseball de retourner la tendance et de gagner le match?

Heureusement, malgré une analyse en profondeur de nombreuses données, le sport reste un domaine qu'on ne peut pas toujours prévoir, pour le plus grand bonheur des sportifs et des spectateurs.

Ainsi, le Big Data a permis au sport d'évoluer ces dernières années. Elle est un outil formidable pour améliorer la performance des sportifs, qu'ils soient amateurs ou professionnels, mais aussi pour améliorer la performance des entreprises. Le Big Data est devenu indispensable pour l'industrie du sport. Grâce au Big Data, les téléspectateurs peuvent également vivre de nouvelles expériences, c'est par exemple le cas avec le « mode expert » de Canal+. Toutefois, il faudra faire attention à l'avenir à ce que l'utilisation massive du Big Data ne vienne pas déshumaniser le sport.

B. Le Big Data et la Santé

Entre solution miracle, coût faramineux et usage de données vitales, l'emploi du Big Data en médecine est celui qui laisse entrevoir les plus grandes opportunités tout en étant au cœur d'enjeux politiques, sociétaux et économiques. Pour introduire ce sujet et illustrer la puissance de l'usage médical du Big Data, intéressons-nous à une étude de cas. En effet, la lutte contre le cancer contre particulièrement bien les enjeux qui gravitent autour de ce sujet.

Etude de cas introductive : Le Big Data dans la lutte contre le cancer

En France, le cancer est la première cause de mort prématurée. 1 homme sur 8 et 1 femme sur 11 meurent de cette maladie. A l'échelle mondiale, environ 20 millions de nouveaux cancers sont diagnostiqués chaque année. De plus, ces chiffres augmentent en permanence pour devenir véritablement affolants.

La progression de ce fléau est liée à l'augmentation de la population mondiale, au développement de nouvelles pratiques le favorisant (tabagisme) et surtout à la difficulté de trouver une solution efficace permettant de soigner toutes les facettes de cette maladie. Certes, la recherche contre le cancer a permet aujourd'hui de guérir 1 maladie sur 2 contre une maladie sur trois il y a 20 ans. Mais la route est encore longue.



La principale difficulté rencontrée par les oncologues est dû au nombre infini de sortes de cancers. Le cancer est un terme générique désignant en réalité une multitude de maladies différentes. D'abord, il existe de grandes catégories de cancers. Les cancers du poumon, du sein chez la femme et de la prostate chez l'homme sont les plus fréquents. De plus, chaque cancer est unique, parce qu'il met en jeu des cellules mutantes qui n'ont rien à voir les unes avec les autres au niveau moléculaire. A cause de cette énorme complexité, il est quasiment impossible pour les chercheurs d'identifier les paramètres qui déterminent l'évolution du cancer.

Mais dans le même temps, cette complexité est une chance pour la médecine. En effet, parce que cette maladie revêt une multitude de formes, nous sommes en mesure de récolter énormément de données à analyser : environ un téraoctet par patient. Les progrès technologiques permettent d'analyser à différents niveaux : les molécules, l'ADN, les tumeurs secondaires… Si au XXème siècle le principal défi des oncologues était la récolte de données, les enjeux aujourd'hui résident plus sur l'analyse et le stockage de celles-ci.

C'est ici que l'on se rend compte de l'immense aide que le Big Data peut fournir dans le domaine de la santé. Le traitement et l'analyse de ces données pourrait permettre de progresser sur de nombreux fronts dans la lutte contre le cancer. L'analyse au niveau cellulaire permet d'anticiper les mutations de la tumeur, l'analyse des antécédents du patient permettent de proposer un traitement personnalisé correspondant à son code génétique et enfin l'analyse globale d'une population permet d'adapter l'équipement nécessaire à une certaine zone géographique et à différents types de cancer.

Si le Big Data est une solution presque miraculeuse dans le combat des oncologues, la mise en place de celui-ci est extrêmement complexe et coûteuse. D'après l'UCSF, en 2017, 1 million de téraoctets de données sur le cancer ont été récoltées au près des patients, ce qui représente 130 milliards de livres et donc 1000 fois que l'ensemble des livres écrits durant l'histoire de l'humanité.

C'est pourquoi l'utilisation du Big Data pour vaincre le cancer devra absolument passer par une solution collaborative, à l'échelle nationale voire internationale. Certains organismes se sont déjà formés, comme Innovative Médecine Initiative qui a proposé plusieurs projets à la commission pour mettre en place une organisation européenne de stockage et traitement des données en rapport avec le cancer.

Revenons au cas général : dans quelles mesures le Big Data peut-il permettre de grandes avancées médicales ? Comment récolter des données et les exploiter ? Quelles sont les limites de ce projet ?

1. La collecte des données

1.1. Quelles données récolter ?

La quantité de données à récolter dans le domaine de la médecine est infinie. Celles-ci proviennent de différentes source :

- **Le patient**. Construire une base de données portant sur l'ensemble de la population et avec les informations médicales principales comme le rythme cardiaque, la respiration ou les heures de sommeil serait d'une grande aide. Mais ces données restent trop générale et certains patients peuvent être une source d'information bien plus riche. En effet, chaque maladie ou forme de mal-être est propice à être analysée à différente échelle (moléculaire, cellulaire, organique ou physiologique) et de différente manière. Cette source d'information est clairement la plus controversée, puisqu'elle s'appuie sur des informations vitales et confidentielles d'individus. Différentes solutions à ces enjeux de confidentialité seront proposées.



- **La recherche médicale**. Depuis la fin de la Seconde Guerre mondiale, certains Etats ont fait de la santé de leur population une de leurs préoccupations principales. Ainsi, les moyens colossaux accordés à la recherche médicale couplés aux progrès technologiques ont permis de faire de nombreuses découvertes. L'ampleur de ces progrès a créé une gigantesque masse de connaissances nécessaires aux médecins et aux chercheurs pour être à la pointe dans un domaine, ce qui a mené à une spécialisation des professionnels de santé dans des domaines précis. Le stockage et la gestion des données qui découlent de la recherche médicale est donc un enjeu capital. La compagnie IBM a par exemple créé le robot Watson (image ci-dessus), qui est déjà

devenu un incontournable dans des centres de santé Nord-Américains. Il centralise des données sur les maladies et tient les médecins au courant des actualités de la recherche médicale. Il est également en mesure d'interagir avec les patients afin de les orienter vers le service de santé le plus adapté.

- **La population**. Avoir une base de données globale sur une population d'une région ou d'un pays permettrait d'analyser la fréquence d'apparition d'une maladie en fonction des conditions climatiques, d'anticiper des épidémies. Le manque d'anticipation de l'OMS lors de la crise sanitaire en 2020 était grandement dû à un manque de données sur la population mondiale. Ces données auraient pu permettre d'observer en tant direct la propagation du Coronavirus à l'échelle planétaire, pour prendre des mesures sanitaires adaptées.



Ainsi, une quantité phénoménale d'informations portant sur le patient, la population ou relevant de la recherche médicale pourrait être récoltée. Mais comment faire ? Par quels moyens peut-on réunir autant d'informations ?

1.2. Comment récolter les données?

Nous allons ici présenter des solutions permettant de récolter cette immense masse de données en rapport avec le domaine médical.

Tout d'abord, il existe déjà différents moyens de récolte et de centralisation des données médicales. Il est important de préciser que si l'appellation de Big Data confère à cette technologie une dimension futuriste, la récolte et le traitement de données est déjà très importante en médecine. Cette récolte de données passe avant tout par des moyens traditionnels. Les visites chez le médecin permettent de mettre à jour certaines informations comme la taille, le poids, les battements du cœur, la mise à jour dans les vaccins. Ces informations sont stockées dans le carnet de santé. Des recherches plus précises peuvent également être effectuées lors d'une hospitalisation ou lors d'examens. Par ailleurs, la mise en vente de nouveaux médicaments ou de vaccins passe par des essais cliniques reposant sur l'étude de milliers de patients volontaires.

Mais ces moyens traditionnels de récolte de données sont limités. L'usage du Big Data en médecine requiert une automatisation des moyens de récolte des données. C'est l'arrivée des objets connectés, très liée à l'implantation de la 5G à grande échelle qui permettra alors de progresser dans ce domaine. Les montres connectées, les capteurs intégrés à la maison permettent d'avoir accès à une quantité importante d'informations sur le patient en temps direct.

L'enjeu est alors de mettre en place les institutions à moyenne et grande échelle permettant de connecter les différents moyens de récolte des données. Cela suppose une collaboration entre les différents acteurs :

- l'Etat peut mettre en place des subventions favorisant la recherche et la construction d'infrastructures favorables au transfert de ces données ultraconfidentielles. L'Etat joue également un rôle important au niveau des normes et des lois relatives à l'exploitation de données dans le cadre du Big Data.
- Les institutions comme les hôpitaux doivent orchestrer la mise en place de réseaux de données, entre le patient, les médecins et les chercheurs. Le CHU de Caen depuis 2005 a importé du Canada un système innovant permettant de suivre à distance des patients souffrant d'une insuffisance cardiaque. Ce moyen suppose un lien continu entre patients et professionnels de santé.
- Les entreprises jouent un rôle important dans le domaine de l'innovation et de la mise en place de nouvelles technologies facilitant le transfert et le traitement des données. SRETT est une entreprise qui met en place des moyens permettant de prendre en charge des patients souffrant de maladies chroniques quelle que soit leur localisation. Les données sont partagées sur VESTALIS, une « plateforme de gestion de données pour la santé connectée ».
- Les patients doivent accepter l'évolution des méthodes de soins et de récolte de données.

Mais une fois ces données récoltées, comment améliorer clairement la médecine et les systèmes de soins à toutes les échelles ?

2. L'utilisation des données en médecine

2.1. Pour prévenir

De manière générale, l'apport principal du Big Data est une forme de connaissance précise en temps direct et accessible simplement. Cette connaissance doit ensuite être mise au service d'acteurs qui peuvent agir en conséquence. Dans le domaine de la santé, les données récoltées permettent bien souvent d'anticiper des phénomènes, que ce soit à l'échelle du corps humain ou d'un pays. Ainsi, le Big Data en médecine permet de prévenir et d'anticiper.

D'abord, le Big Data permet de prévenir des épidémies en relevant des informations à grande échelle. En effet, les informations sur la propagation de certains symptômes à l'échelle régionale, doublées d'une intelligence artificielle, permettent d'améliorer l'anticipation de certaines maladies. A l'échelle mondiale, des épidémiologistes américains ont développé le site HealthMap, qui prévient la propagation de certaines maladies infectieuses en se basant sur des données récoltées dans des hôpitaux locaux ou à l'échelle d'un pays.

De plus, la mise en place d'un flux de données continu reliant un patient à un professionnel de santé permet de détecter des signes avant-coureurs de maladies ou d'infections virales chez le patient. Dans le cas du cancer, cela permet de détecter une tumeur lors de son apparition, afin de commencer la chimiothérapie beaucoup plus tôt, ce qui multiplie les chances de rémission. C'est surtout dans le domaine de la surveillance cardiaque que le Big Data est d'une grande aide pour prévenir un infarctus.

Etude de cas : le Big Data et la surveillance cardiaque

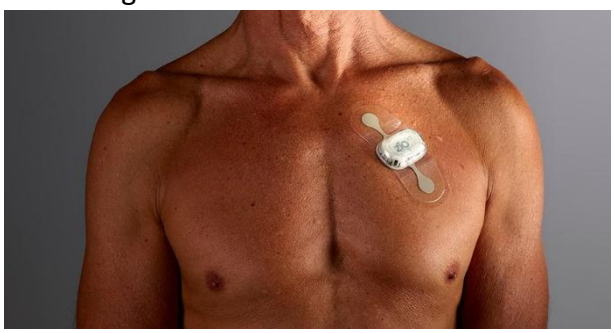
L'infarctus est la maladie cardiovasculaire la plus meurtrière : chaque année, il est responsable de 18 000 morts en France. La difficulté pour les médecins est de ne pas pouvoir suivre en direct le rythme cardiaque des patients, qui sont donc souvent pris en charge trop tard lorsque l'infarctus survient. Une politique visant à rendre les électrocardiogrammes et surtout les défibrillateurs plus accessibles permet de sauver des vies mais présente tout de

même des limites : inégalités entre les patients urbains (plus vite pris en charge) et ruraux, nécessité d'être entouré par quelqu'un sachant se servir de ces instruments…

C'est pourquoi le marché de la surveillance cardiaque grâce à une collecte massive d'informations s'est fortement développé ces dernières années. En effet, le développement des Smartphones et d'objets connectés a permis d'augmenter les flux de données et donc de suivre des millions de patients en temps direct.

C'est LifeWatch qui ouvre la marche en sortant des capteurs ECG miniaturisés, permettant de suivre en permanence le rythme cardiaque d'un patient et lançant une alerte à un médecin à proximité lors de la détection d'un signe anormal. En compétition avec Philips, General Electrics, iRythm et Preventice Solution, les progrès technologiques sont extrêmement rapides.

Si prévenir vaut mieux que guérir, le Big Data est d'une grande aide à la médecine. Néanmoins, la prévention seule ne suffit pas en matière médicale, et le Big Data permet également d'améliorer les traitements des patients déjà atteints de certaines maladies.



2.2. Pour guérir

Le Big Data intervient à de nombreux niveaux lors de la guérison de patients. En réalité, le Big Data est déjà présent à chaque étape du processus de guérison : recherche médicale, développement de traitements, identification de la maladie, détermination du traitement, aide à la prise du traitement.

Amélioration des tests des médicaments : Un point intéressant illustrant l'aide du Big Data dans la guérison de patients réside dans le test d'efficacité de nouveaux médicaments ou traitements. En effet, l'efficacité d'un traitement était testée auparavant seulement en fonction de la dose d'anticorps présents après et avant la prise. La capacité de stocker et de traiter efficacement un nombre de données beaucoup plus élevé permet de prendre en compte de nouveaux critères d'évaluation des médicaments. Par exemple, ces tests

interviennent désormais au niveau cellulaire. De même, la gestion des données pour le développement de vaccins contre le Coronavirus était évidemment capitale.

Des enjeux économiques : L'utilisation du Big Data pour guérir des patients relève d'enjeux économiques. En effet, l'analyse de données à grande échelle permet de diminuer le coût des soins. Par exemple, aux Etats Unis, plus d'un tiers de la population souffre d'obésité. Une solution efficace contre cette situation sanitaire est de coupler une chirurgie de l'obésité (modifiant l'anatomie du système digestif) à un accompagnement sur le long terme permettant une modification du mode de vie du patient. Dans cette solution, l'opération coûte 30% et la récolte de données pour le suivi après traitement 70%. Or la seconde étape est souvent mal réalisée : à cause d'un manque de suivi régulier, de nombreux Américains ne parviennent pas à changer leurs habitudes de vie et l'opération chirurgicale n'est alors d'aucune utilité. Pour lutter contre l'obésité, l'utilisation du Big Data a permis de mettre en place des systèmes de suivis personnalisés des patients après leur opération, qui sont à la fois plus efficaces et moins coûteux. Il est ainsi estimé que l'application du Big Data à la santé a permis aux Etats Unis d'économiser 300 milliards de dollars par an, soit 40% du budget militaire Américain.

2.3. Pour la recherche médicale

Appliqué à la recherche médicale, le Big Data permet de créer des plateformes de collaboration entre chercheurs, médecins et patients. Le Big Data permet ici de connecter différents groupes d'individus et d'accélérer un processus dans le cadre d'une relation gagnant-gagnant. Les patients mettent à disposition leurs informations personnelles, qui sont traitées afin de proposer des bases de données facilitant le travail des chercheurs. Les progrès en médecine et sur la connaissance de diverses maladies permettent alors aux médecins de proposer des traitements plus efficaces aux patients.

L'application mPower met en place ce concept pour la maladie de Parkinson. Les patients peuvent partager leurs symptômes comme une déviation de la voix ou de la démarche et ont même la possibilité de réaliser des tests comme le "finger taping", lors duquel ils tapent des doigts sur l'écran de leur téléphone, données faisant ensuite l'objet d'études précises. Le même genre de partage de données a permis le développement de pancréas artificiels pour aider au quotidien les individus souffrant du diabète.

Ainsi, l'exploitation des données médicales a un potentiel et relève parfois d'une solution miracle. Mais ce Big Data de la santé peut mener à des dérives et parfois présenter des limites. Le Big Pharma est-il réellement une solution viable ?

3. Les limites

3.1. Dangers de l'Open Data dans le système médical

L'Open Data renvoie à un système complexe de flux de données totalement perméable, dans lequel chacun a accès à des données privées moyennement paiement. La valorisation financières de données médicales parfois vitales mène à des dérives de l'utilisation du Big Data dans la santé.

En mai 2021, Cash Investigation révèle que dans la moitié des pharmacies françaises, les informations relatives à la vente de médicaments sont revendues à la société Iqvia, leader mondial de gestion de données médicales. Alors que la loi stipule que chaque citoyen devrait être en mesure de refuser de partager ses données personnelles, aucun processus ne permet cette opération. Ainsi, à chaque fois que les français présentent leur carte vitale dans l'une des 14 000 pharmacies partenaires d'Iqvia, ses informations personnelles sont répertoriées et l'individu est alors tracé, tout un suivi médical informatique est mis en place. Ce scandale a été une véritable prise de conscience des dangers du Big Data appliqué à la santé.

Dans Le business de nos données médicales: enquête sur un scandale d'État, Audrey Boulard, Eugène Favier-Baron et Simon Woillet, décrivent les dérives du Big Pharma. Ils expliquent que les données médicales représentent un marché de 7100 milliards de dollars pour les GAFAM, et donc suscitent un grand intérêt : Doctolib vend ainsi les données de ses utilisateurs à Facebook. De plus, il est désormais possible d'acheter le dossier médical de nimporte quel individu pour une valeur de 700 euros sur le DarkNet. Ces données suscitent ainsi l'intérêt des assurances. Pour les auteurs de ce livre, ces dérives sont au cœur d'un virage

philosophique et politique au sein de nos sociétés, ils considèrent que notre façon de percevoir la santé évolue.

3.2. Problèmes de stockage de données

L'accumulation des données médicales entraîne la formation de masses de données gigantesques. Des espaces de stockage gigantesques et coûteux et des supercalculateurs doivent alors être construits. Cela pose des problèmes financiers et crée des injustices puisque l'ensemble des hôpitaux n'est pas en mesure de financer de tels instruments informatiques. De plus, les technologies nécessaires à la mise en place du Big Data dans la santé sont inégalement réparties sur le globe et de nombreux pays du Sud n'ont pas accès à ces versions performantes de la médecine.

Un autre problème posé par les données de santé est la standardisation des données. En effet, ces données sont souvent de nature et de format différents et ne conviennent qu'à des systèmes d'exploitation spécifiques. Cela empêche la mise en place d'une gestion des données à grande échelle.

3.3. Solution

Face aux limites relatives à la sécurité de données confidentielles et aux problèmes de stockages, une collaboration internationale s'impose. En effet, la mise en place d'un serveur de gestion globale des données permettrait à la fois de faire des économies d'échelle sur le stockage des données, de forcer les différents acteurs de la santé à standardiser les formats de données utilisés et surtout de mettre en place des politiques de confidentialité globales sur ces données. En effet, les différences de réglementation ou de formats permettent aux acteurs malveillants de jouer sur les différences de réglementation et donc de revendre des données médicales de manière légale.

Le 12 juillet 2022, le Comité Européen de la Protection des Données a publié un avis conjoint à la Commission Européenne mettant en place une procédure d'identification des cas transfrontaliers de transferts de données de santé. Ces différentes mesures législatives sont

nécessaires, mais pas suffisantes, puisqu'elles ne prévoient pas la formation d'un centre de gestion des données de santé à l'échelle européenne.

C. Le Big Data représente un avantage certain pour les entreprises

1. La connaissance du consommateur

La maîtrise du Big Data est aujourd'hui centrale pour les entreprises. Nous sommes effectivement entrés dans l'ère de la « 4ème Révolution Industrielle » (Klaus Schwab), celle de la donnée de masse. Les entreprises les plus performantes de nos jours sont bel et bien celles qui ont su saisir l'opportunité de se développer dans ce domaine. On peut ici penser aux GAFAM américaines (Google, Apple, Facebook, Amazon et Microsoft) ainsi qu'aux NATU (Netflix, AirBnB, Tesla et Uber) qui ont su se développer via l'utilisation et le contrôle du Big Data. Mais quels avantages le Big Data peut-il représenter pour les entreprises ? Et comment ces firmes américaines ont-elles su se hisser au sommet de la hiérarchie grâce à cette maîtrise du Big Data ?

Il faut en premier lieu noter qu'analyser ses consommateurs, c'est connaître ses consommateurs. Et c'est une chose que les entreprises de la Big Tech ont comprise. En effet, connaître ses consommateurs, c'est être plus susceptible de leur vendre ses produits. C'est pourquoi les entreprises mettent désormais l'accent sur la collecte et l'analyse de données des consommateurs. Et plus il y a de données, plus l'entreprise connaît avec précision ses consommateurs. C'est notamment ce que met en avant le reportage sur Netflix « Derrière nos écrans de fumée ». Ce documentaire aux allures alarmistes met en avant une chose : tous les produits que nous consommons en ligne et qui apparaissent gratuits ne le sont pas. Si on pense que le produit est gratuit, alors c'est que nous sommes le produit. En effet, les entreprises cherchent à établir un profil type en fonction de chaque utilisateur. Et chaque donnée récoltée permet d'affiner petit à petit ce profil, pour en obtenir un très détaillé à la fin. Mais à quoi un tel profil détaillé peut-il servir aux entreprises ?

Connaître aussi précisément ses consommateurs, c'est connaître leurs habitudes d'achat, leurs centres d'intérêt, leurs goûts… Et donc à terme connaître ce qu'ils sont susceptibles, ou non, de consommer. Cela passe tout d'abord par la mise en avant de publicités ciblées. On peut prendre l'exemple de YouTube, qui propose des publicités en fonction des dernières vidéos regardées, des recherches Google effectuées ou encore en fonction de l'âge, du sexe

et de l'origine de la personne. De telles publicités ont un double but : tout d'abord, essayer de faire acheter au consommateur, en lui proposant des produits susceptibles de l'intéresser. Dans un second temps, et encore une fois cela est largement expliqué dans « *Derrière nos écrans de fumée* », l'objectif est de garder le consommateur connecté au site internet de l'entreprise. Pour YouTube, cela va donc être de le garder le plus longtemps à regarder des vidéos. Pour TikTok, l'objectif va être de faire scroller l'utilisateur pendant de longues minutes, voire des heures.

Par ailleurs, connaître ses utilisateurs permet de faire un marketing avec une efficacité redoutable tout en gardant des prix raisonnables. En effet, nous avons déjà vu que proposer des publicités ciblées était un des objectifs de ces entreprises. Mais il y a également un côté plaisir qui est à prendre en compte. Puisque l'entreprise connaît les centres d'intérêt de ses consommateurs, elle va lui proposer du contenu qui lui plaît. Celui-ci va donc avoir à retourner sur le site de l'entreprise, voire à en parler à ses proches (amis, famille, collègues) et ainsi faire du marketing malgré lui pour ladite entreprise. Maîtriser le Big Data est aujourd'hui indispensable pour les entreprises de la Tech si elles veulent garder une visibilité tout en répondant aux attentes de leurs consommateurs.

2. La gestion des risques

Ainsi, la maîtrise du Big Data permet aux entreprises de connaître leurs consommateurs en amont. Elle lui propose ainsi les produits qu'il est le plus susceptible de consommer. Mais contrôler le Big Data présente également un intérêt majeur en aval. Cela permet notamment une gestion des risques à prix réduit, voire de prédire l'avenir pour maximiser au maximum les coûts. On peut ici prendre l'exemple d'Amazon. À chaque période de Noël, les gens ont logiquement tendance à acheter plus de produits sur le site en ligne. Sauf que si Amazon souhaite augmenter ses stocks, il faut bien les garder quelque part. or cela représente un coût, en matière de logistique, de sécurité, etc. C'est ainsi qu'en analysant les données des personnes visitant son site qu'Amazon parvient à réaliser des économies. En effet, le site regarde de manière poussée l'historique des consommateurs et prévoit en avance les stocks des articles les plus visités mais qui n'ont pas encore été achetés. Et force est de constater

que cela est rentable pour l'entreprise, qui réalise ainsi de grandes économies par l'analyse des données des consommateurs.

Le Big Data encourage également l'innovation. Lorsqu'une entreprise propose un service ou produit innovant et inédit, une maîtrise poussée du Big Data permet de savoir rapidement si le service ou le produit est performant ou non. Et cela permet deux choses. Tout d'abord, cela pousse à l'innovation : une entreprise innovante est une entreprise gagnante. Or, si elle a un moyen de mesurer facilement la rentabilité d'un produit, elle a intérêt à en proposer de nouveaux régulièrement puisqu'elle peut facilement se rétracter. Ainsi, elle peut plus facilement proposer des produits innovants. Et plus que de proposer un produit directement, elle peut sonder l'habitude de ses consommateurs afin d'évaluer si ce produit va fonctionner ou non. L'établissement du profil de ses consommateurs permet en effet de prédire ceci de manière plus ou moins fiable. Et la deuxième chose qu'une analyse poussée du Big Data permet découle directement de la première : une gestion des risques à un prix faible. En effet, en prédisant le comportement de ses consommateurs, l'entreprise minimise les marges d'erreur et donc devient encore plus rentable.

Il faut par ailleurs noter que le Big Data appliquée aux ressources humaines dans une entreprise peut permettre de prévoir des problèmes futurs. En effet, en analysant l'habitude des consommateurs, il peut devenir intéressant d'établir une liste des tendances actuelles, et donc des domaines qui deviennent plus cruciaux qu'ils ne pouvaient l'être. Il peut donc être plus qu'intéressant pour une entreprise de recruter dans ce domaine-là, afin d'être dans les précurseurs ou du moins de pas être en retard par rapport à la concurrence, et toujours maximiser son profit.

Et évidemment, un des domaines cruciaux pour laquelle l'analyse des données est rentable pour l'entreprise concerne l'aspect financier. Cette dernière peut tout d'abord avoir une meilleure visibilité sur l'évolution du marché, notamment en récupérant de la data exogène par crawling et scraping. Ce sont des méthodes pour récupérer des données en extrayant les données d'une page web. L'entreprise peut également prévoir de nouveaux modèles.

Enfin, une analyse poussée des données des consommateurs permet à l'entreprise de savoir quelle est exactement sa réputation en ligne. Or aujourd'hui, il est de plus en plus indispensable d'avoir la meilleure réputation sur internet pour gagner fidéliser les clients et en gagner de nouveaux. Ainsi en analysant toutes les données pouvant concerner l'entreprise

et qui ont été émises par les consommateurs, cette dernière peut décider de changer sa stratégie (qui peut ne pas s'avérer payante), ou au contraire continuer dans celle-ci si jamais elle est pertinente et plaît aux consommateurs.

3. Le problème de concurrence deloyale

Cependant, si l'analyse du Big Data semble plein d'avantages pour les entreprises, et semble être un formidable levier de croissance, un problème sous-jacent réside : le Big Data profite bien plus aux grandes entreprises qu'aux PME. En effet, maîtriser et savoir analyser correctement le Big Data est d'autant plus pertinent que l'échantillon est large. On s'aperçoit qu'il y a ici un problème. En effet, les grandes entreprises de la tech, les Big Tech Companies, que ce soient les américaines GAFAM ou NATU, ou encore les chinoises BATHX, comptabilisent un nombre astronomique d'utilisateurs et par conséquent un nombre très important de données qu'elles peuvent analyser comme bon leur semble. Et évidemment ces données restent la propriété des entreprises. Mais puisque leur échantillon est très large, ces entreprises vont ainsi avoir des profils très précis sur leurs consommateurs, profils qui vont être très divers. On peut par exemple prendre l'exemple de la firme californienne de Mark Zuckerberg, Facebook. En octobre 2022, elle comptabilise presque 3 milliards d'utilisateurs actifs dans le monde, un nombre inédit. Avec de telles ressources en termes de data, il est aisé pour Facebook d'établir des profils types. Elle possède tout d'abord notre liste d'amis, les photos que nous avons postées, les publications que nous avons partagées, ce qui permet ainsi d'établir une carte des goûts et centres d'intérêt du consommateur. Mais même une personne qui ne poste rien sur le réseau social se voit attribuer un profil assez précis le concernant. En effet, le moindre « like » que nous laissons renseigne l'entreprise sur nos goûts et nos centres d'intérêt. L'entreprise sait également quand nous restons devant une vidéo plus de quelques secondes, ce qui la renseigne sur le fait que ça nous intéresse. Ainsi, des géants du numérique tel que Facebook se retrouvent avec des données précises, variées, concernant des milliards d'utilisateurs. À l'inverse, une PME qui ne compte que peu de consommateurs aura bien moins de données à analyser, et donc ses profils seront moins précis et moins variés. Mais cela implique donc que les entreprises qui vont le plus profiter des avantages du Big Data sont déjà les plus grosses entreprises. Dès lors, le Big Data qui est

mis en avant comme levier de croissance exceptionnel pour les entreprises ne semble qu'entretenir qu'une simple concurrence déloyale.

En effet, les entreprises qui vont le plus bénéficier des avantages de maîtriser le Big Data sont celles qui sont le plus développées et possèdent déjà le plus de données. Mais en profitant des avantages cités ci-dessus, ces entreprises vont encore plus se développer, et ainsi accumuler encore plus de données. Ceci représente donc un cercle vicieux : les PME n'ont donc pas, ou très peu de chance, de se développer en utilisant le Big Data puisque les avantages qu'elles pourraient en tirer ne font pas le poids face aux géants du numérique. Dès lors, comment résoudre ce problème ? Faudrait-il rendre publiques les données de toutes les entreprises, les considérer comme un bien commun afin que toutes les entreprises puissent s'en servir pour se développer ? Cela amène un problème de vie privée : le consommateur ne veut pas forcément que ses données soient partagées. Alors faudrait-il limiter l'usage que font les entreprises de nos données ? Mais est-ce réellement possible dans les faits ?

On aperçoit ainsi que si les données, leur analyse et leur utilisation semble représenter un gain formidable pour les entreprises, que ce soit en matière de connaissance de son consommateur, ou encore en termes de gestion de risque, la concurrence demeure aujourd'hui déloyale entre des géants du numériques qui bénéficient clairement de ces données et des entreprises plus petites qui peinent à faire face à la concurrence.

Après une analyse des différents bénéfices tirés grâce au Big Data et à son utilisation au quotidien, il convient désormais de voir s'il pourrait être en mesure de résoudre d'autres problèmes d'ordre sociétal.

III. L'évolution du Big Data peut-elle permettre de répondre aux enjeux sociétaux ?

A. Que faire dans les faits? Quelle gouvernance pour le Big Data?

Les risques d'une utilisation aveugle des BDA révèle l'importance de prendre des mesures concrètes pour construire une gestion plus éthique des données. On peut se demander de quels acteurs peut-on espérer des initiatives dans ce sens et quelle efficacité espérer de ces actions.

1. Une ressource détenue par des acteurs privés

L'explosion des données s'est accompagné d'un essor économique : on estime que les revenus générés par les entreprises de Big Data Analytics ont atteint 5.29 milliards de dollars pour l'année 2020 et compteraient pour 51.59 milliards de dollars en 2028 (Vailshery, 2022). Les perspectives offertes par le Big Data ont conduit les entreprises à inclure l'utilisation du Big Data dans leurs stratégies (fig. A). La conséquence est que les données sont presque entièrement générées par des acteurs privés et contrôlées par des acteurs privés.

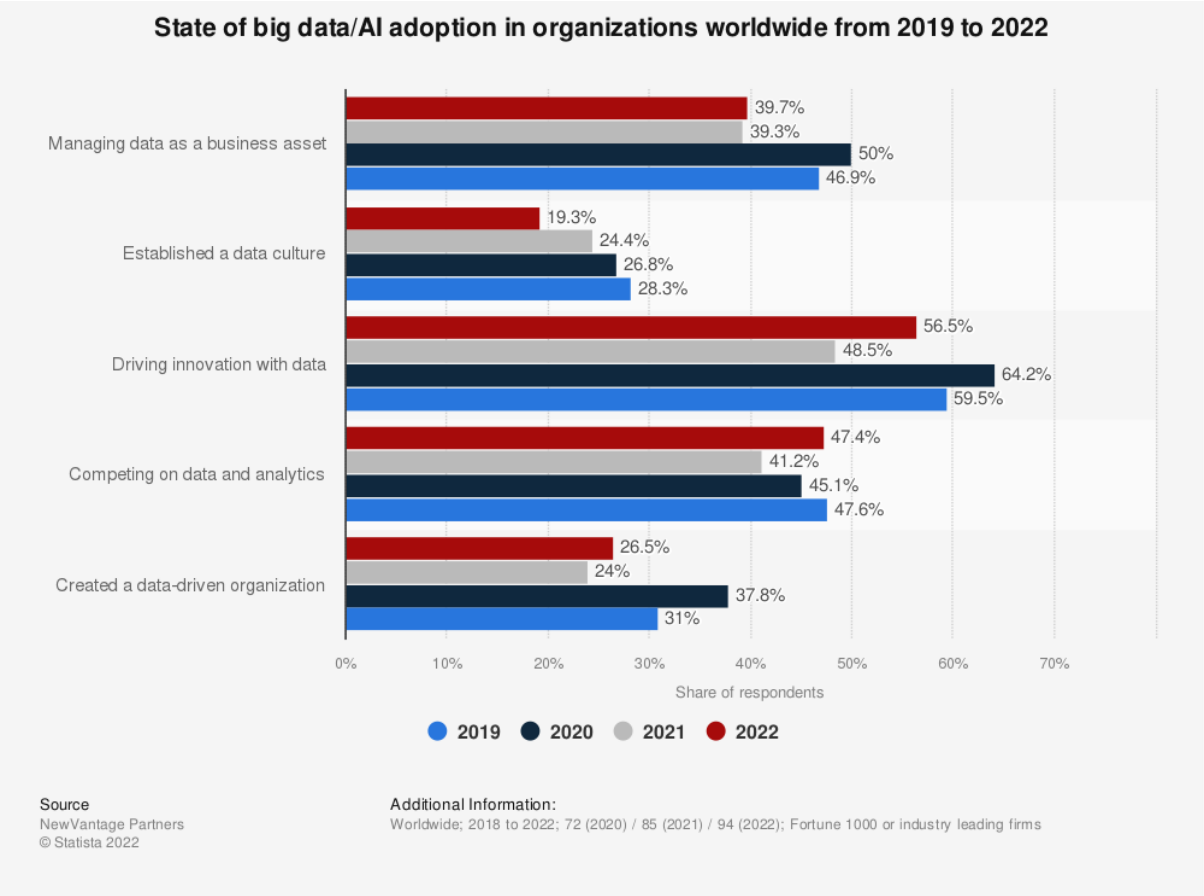


fig. A

Les méthodes principales de collecte des données que sont les objets intelligents, les enregistrements des ventes, des déplacements, les informations télémétriques et les cookies sont employés principalement dans un but commercial. Il devient alors crucial de se demander comment transposer le potentiel des données collectées dans le développement de solutions pour le développement social.

2. Mise en place d'un cadre légal

Les entreprises doivent prendre en compte les risques induits par une utilisation croissante des données dans leurs stratégies. En effet, les données sont dorénavant considérées comme des actifs que les entreprises doivent protéger afin de conserver leur valeur. Cette valeur tient du fait que les données représentent une ressource que l'on « mine » ou « extrait » au même titre que certaines ressources naturelles. De cette valeur s'accompagne alors un risque proportionnel. Pour faire face à ces risques, les entreprises mettent au point des outils, en interne, qui sécurisent leurs données. La gestion des données

privées par les entreprises constitue le second risque majeur auquel elles font face. Pour contrecarrer ces risques, les entreprises ne doivent pas être adversaires, mais alliées. Que faire précisément ? Les entreprises doivent prendre de la hauteur sur leur gestion de leurs données, et les analyser correctement afin d'évaluer les risques en jeu. Ensuite, elles doivent mettre en place une gouvernance autour des données. L'accessibilité croissante aux données publiques (on parle d' « open data ») conduit les États à réguler leur utilisation. Les secteurs les plus concernés sont alors les secteurs dits « sensibles», à savoir la santé et le secteur social. Des propositions voient alors le jour, tant au niveau européen qu'à l'échelle nationale. Ces propositions et textes émergent suite aux nouvelles tendances associées au Big data : la multiplication des acteurs producteurs de données (comme les individus) et l'augmentation de variétés des types de données (elles disent aujourd'hui tout de notre intimité). Ces données sont intrinsèquement neutres. C'est l'utilisation que certains acteurs en font (comme le profilage) qui peut porter atteinte à la vie privée. C'est pour cela que l'Union européenne s'attelle à rendre aux individus leurs droits sur leurs données personnelles. Si le droit ne doit pas être un frein au développement du Big data, il doit être capable, à toutes échelles, de le réguler. Les professionnels du monde de la Data ont confirmé que l'action de l'Etat est nécessaire pour mettre en place des règles pour réguler la gestion de la donnée. Les entreprises sont soumises par exemple aux règles du RGPD, qui obtient l'adhésion de la plupart des employés au sein des entreprises mais qui dans un contexte de compétitivité et de rivalité avec les autres entreprises n'auraient pas mis en place les outils nécessaires pour permettre aux utilisateurs d'avoir le contrôle sur leurs données personnelles. L'action des gouvernements et l'action législative doit continuer à mettre en place des cadres pour permettre aux citoyens de s'intéresser au sujet des données de poser les bases pour une gestion partagée de l'usage des données. On peut toutefois s'interroger sur la nature des réglementations que l'on peut mettre en œuvre, car si le RGPD existe, il est difficile pour le consommateur de l'utiliser, car le consentement du don des données est fait parfois par la force ou par praticité.

3. Obtenir une classification des algorithmes comme nouvelle approche de la régulation des outils issus du Big Data

Le principal problème des outils du Big Data (BDA) réside dans le manque de transparence, non seulement de la génération des données, mais aussi de la génération des résultats. Afin de mieux contrôler la pertinence des algorithmes, il a été proposé de créer une classification des algorithmes (Saldanha et al., 2022). Différents critères pourraient être retenus pour tester les algorithmes et s'assurer qu'il n'y a pas de biais discriminatoire (notamment dans les algorithmes de recrutements et de prise de décisions). Il a été proposé de développer une "responsabilité des algorithmes". De cette manière, les entreprises à l'origine de ces algorithmes pourraient avoir la responsabilité de rendre transparents les algorithmes issus de l'analyse du Big Data. Cette mesure serait mise en place par un gouvernement afin de pouvoir contrôler sa mise en application. La conséquence d'un tel système serait un contrôle bien meilleur de l'utilisation des algorithmes et un moyen de surveiller les biais des algorithmes. N'oublions pas que dans certains cas, l'itération d'un algorithme biaisé au départ entraîne un renforcement des biais et non une rectification. Dans le cas des algorithmes de recrutements, aucun test n'a été effectué pour s'assurer que les algorithmes employés ne sont pas biaisés avant leur mise en application. Le lien entre conséquence de l'utilisation des algorithmes et responsabilité des entreprises ne peut être fait juridiquement que sur la condition de l'existence de telles règles. L'idée est que le traitement des données est plus important que les données elles-mêmes. Si les données de départ sont biaisées, l'entreprise ou le gouvernement qui met en place les algorithmes doit être capable d'établir un rapport de fiabilité sur les résultats de l'algorithme. Un test de ce genre peut aisément être effectué à l'aide d'un échantillon test. Le problème sous-jacent à cette méthode est qu'il peut être difficile de définir à quel point un algorithme est biaisé. Si le moindre biais de départ peut prendre une grande ampleur à long terme, un des moyens de s'assurer des résultats de l'algorithme serait de le contrôler régulièrement.

4. “Anonymiser” la Data, une réponse de la recherche au problème de la gestion des données

De nombreux travaux de recherche se concentrent sur la manière dont les programmes de collecte et de traitement des données peuvent empêcher de pouvoir retracer les personnes physiques à l’aide de leurs données. Plusieurs avancées notables telles que les algorithmes ImSKA (Improved Scalable k-Anonymity) et ImSLD (Improved Scalable l-Diversity) permettent d’anonymiser efficacement des bases de données d’une certaine taille (Mehta & Rao, 2022). Le rôle des entreprises et des institutions nationales de la Data est crucial pour la mise en application de ces algorithmes. Un des aspects fondamentaux qu’il faut encore améliorer reste le coût de faire fonctionner ces algorithmes. Le fonctionnement de ces algorithmes représente un certain coût en électricité et en temps de traitement qui ne doit pas dissuader les organismes de collecte de données et les organismes de collecte de données de les mettre en place. L’enjeu fondamental est de réussir à “désassembler” les profils (la méthode actuelle proposé dans l’algorithme ImSLD est la création de classes d’équivalence pour trier les données plutôt que d’avoir des profils, ce qui empêcherait de retracer les individus).

5. Vers une Data gérée par des citoyens?

Les citoyens sont jusqu’à présent des acteurs passifs qui subissent la collecte de données. Un des facteurs de ce phénomène est le manque de compréhension du fonctionnement du traitement de la Data (Janssen & Kuk, 2016). Il est préconisable de développer une gestion de la Data collective et cela nécessite de rendre les algorithmes de traitement des données transparents. Afin de mieux comprendre le fonctionnement du Big Data, il peut être proposé aux populations des formations, notamment au sein des universités. Plusieurs initiatives sont encore à explorer pour le formation des populations à la compréhension des enjeux du Big Data et de l’intelligence artificielle. L’initiative la plus prometteuse est la “Explained Artificial Intelligence” (XAI, Intelligence artificielle expliquée). Cependant, trop peu de recherches ont

été effectuées pour connaître l'efficacité de ces méthodes notamment auprès des personnes peu éduquées (Haque et al., 2023). Ces méthodes, qui existent pourtant depuis 2004 pour le secteur militaire (Zhang et al., 2022), pourraient permettre de remettre "l'humain dans la boucle" (Bauer and Baldes, 2005, Tamagnini et al., 2017, Zhu et al., 2018, Abdul et al., 2018). Il serait possible d'établir des forums de discussions publiques au sein des démocraties afin de mieux permettre à la population de comprendre ce qu'est le Big Data et ce qu'il représente et comment on peut le mettre à contribution dans le cadre des politiques sociales. L'éducation peut également tenter d'aborder le Big Data et l'intelligence artificielle dans les écoles, afin de familiariser les populations avec ces outils, et prévenir un phénomène d'écartement entre la réalité des technologies utilisées dans notre quotidien et le niveau de connaissance des populations sur ces technologies afin de permettre d'implémenter dans la culture la nécessité de protéger les données privées, et de prendre ses précautions face aux algorithmes sans pour autant les rejeter. Il est important d'introduire suffisamment de nuance pour que les BDA soient utilisées et développées au mieux dans le cadre d'un développement social partagé et co-conduit par les citoyens au sein des démocraties.

B. Les limites du Big Data

Avant de considérer le Big Data et l'algorithmique comme un remède miracle aux problèmes sociaux, on peut raisonnablement s'interroger sur les limites de cette technologie. Est-ce que tout le monde peut bénéficier de cette technologie? En particulier, de quels moyens faut-il disposer pour mettre en place des plans nationaux de mise en valeur du Big Data au sein de projets de développement social? Sur le plan technologique, quels problèmes peuvent notamment être issus de la surabondance des données? L'acteur humain chargé de la conception des méthodes de traitement peut-il toujours prévoir les conséquences de son algorithme? Ou au contraire est-il très facilement dépassé par ce dernier?

1. Une solution coûteuse

L'implémentation des technologies d'analyse Big Data (Big Data Analytics) implique des investissements importants de capitaux humains, technologiques et financiers (Galetsi et al., 2022, Bibri, 2019). Les Data Centers sont des infrastructures de plusieurs millions de dollars dont l'installation et l'alimentation nécessitent un approvisionnement en fonds important. Pour que des projets sociaux puissent être mis en place par des acteurs privés, il faut qu'ils soient convaincus par la rentabilité du projet ou bien parfois que ces projets aient lieux dans des endroits proches des grandes firmes (on peut prendre l'exemple de Goldmann Sachs qui a investi 2 milliards de dollars sur un plan de 10 milliards au total pour améliorer les conditions d'accès à l'éducation des femmes dans la banlieue de New York notamment). Dans la plupart des cas, l'Etat est à l'origine de tels programmes. Alors que des moyens sont mis en place dans les pays développés, il est encore difficile d'implémenter les solutions de BDA dans les pays en voie de développement. Un tel projet nécessiterait:

- Ou la coopération entre les acteurs privés (qui collectent les données) et les Etats qui souhaitent mettre en place les projets de développement,
- Ou la collecte des données par l'Etat qui doit alors mobiliser des moyens importants pour le stockage des données, la collecte des données et le traitement des données.

On constate malheureusement que les pays en développement, qui pourraient obtenir les plus grands avantages à mettre en place les solutions d'analyse prédictive du Big Data sont également les plus démunis pour l'implémentation de cette technologie. Cette dernière nécessite par ailleurs une maîtrise du réseau électrique. Pour certains pays en développement (Afrique du Sud, Nigéria, Colombie…), dans le cas où l'Etat souhaite implémenter les méthodes de Big Data Analytics pour développer des programmes publics de développement social, il est obligé de coopérer avec des institutions étrangères qui peuvent ne pas être d'accord avec le but des politiques menées. Les entreprises et fonds étrangers sont alors essentiels au développement d'une structure compatible avec la récolte des données et le traitement de celle-ci. Les entreprises sont très souvent les seules capables de mettre en place les moyens de collecter les données. La mise en place des capteurs (par exemple dans le cadre d'un projet existant en Afrique du Sud concernant les chaînes de production de diamants et la prévision des événements climatiques extrêmes (Bag et al., 2022)) sont à la charge de l'entreprise exploitante, très souvent étrangère. Cette grande dépendance rend difficile la mise en place de programmes sociaux construits à l'aide des Big Data Analytics. On peut toutefois espérer que le progrès obtenu par les entreprises privées en matière de Big Data se répercute sur les mesures sociales des gouvernements. En plus de cela, l'accès à des Data Center et à des serveurs de traitement des données requiert soit des grandes infrastructures électriques sur le sol national soit une dépendance aux entreprises de traitement étrangères. La première étape afin de mettre en place de telles capacités réside donc dans le développement d'un réseau électrique viable. Des technologies telles que les micro-réseaux électriques qui pourraient également contribuer à augmenter le niveau de développement des populations sont encore trop peu répandus. Dans ces conditions, il est d'abord primordial de concentrer les fonds des Etats des pays en développement à faible niveau de vie sur les infrastructures, et de confier la gestion des Data à des organismes étrangers. Pour cette raison, la recherche sur le Big Data reste encore limitée à des pays développés (fig. A).

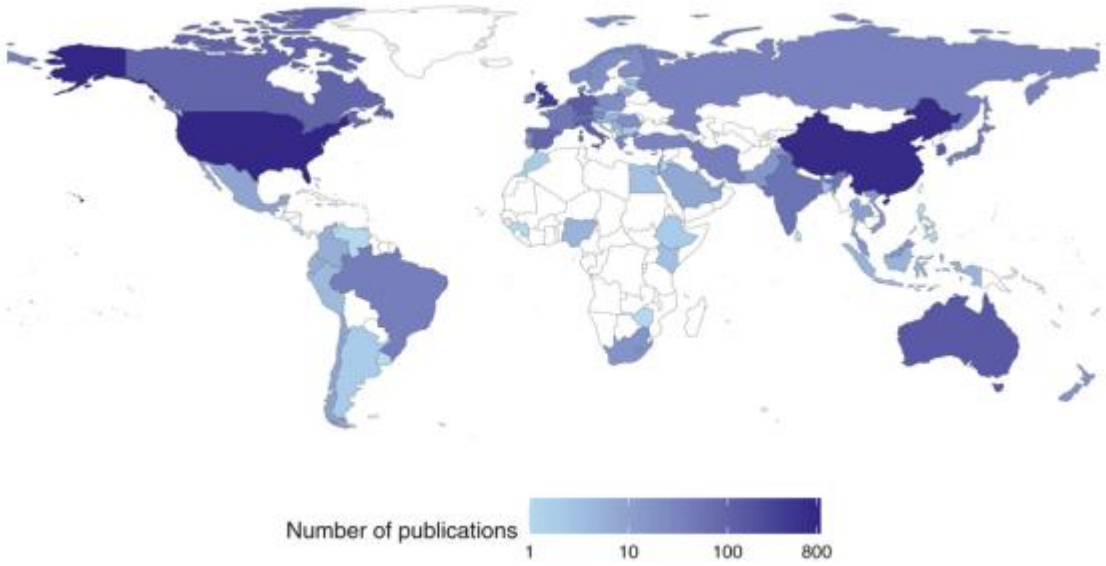


fig. A : nombre de publications de recherche sur le Big Data par pays, on peut identifier plusieurs pôles de recherche importants, l'Amérique du Nord, l'Asie, l'Europe, le Brésil, l'Océanie et l'Afrique du Sud.

2. Les risques technologiques et le manque de transparence

Le premier risque lié à l'accumulation des données repose dans la possibilité de piratage des données. A l'instar du piratage de Yahoo en 2016 de 500 millions de comptes, un piratage massif des données médicales par exemple pourrait tout à fait se produire et avoir des conséquences désastreuses. Cette proportion au désastre est accentuée par la mise en ligne volontaire de milliers d'informations personnelles sur les réseaux sociaux chaque jour. Les données postées sur les réseaux sociaux et les *likes* sont non seulement déjà suffisants pour déterminer avec une grande précision le profil des personnes, mais il y a sur ces plateformes de grands risques de piratage (Mansour, 2016), rappelons que connaître les *likes* d'un profil est suffisant pour déterminer des éléments comme l'orientation sexuelle (Kosinski *et al.*, 2013).

En plus de ce risque, il est nécessaire d'établir une transparence des méthodes de collectes des données et de la conception des algorithmes. Dans le domaine de la recherche biologique, la collecte des données pour établir des modèles ou dans le cadre de recherches scientifiques est délaissée de plus en plus par les chercheurs eux-mêmes. Ce phénomène de

découplage, mis en évidence en 2016 (Devictor & Bensaude-Vincent, 2016) entraîne une baisse de la qualité des données et de leur compréhension (Arpin, 2020). Dans le cas du Big Data, il est possible voire même probable que les bases de données soient constituées de manière opaque, même pour les concepteurs d'algorithme et les analystes experts de la Data à cause de la pluralité des données, et de l'absence de contrôle sur l'origine des données. Cette situation est illustrée ci-dessous (fig. B). L'acteur humain (agent extérieur à la production des données) établit un algorithme non adapté à la nature des données collectées. Le décideur s'appuie alors sur un résultat d'analyse erroné. Soit le décideur s'en rend compte immédiatement après l'expérience, soit l'erreur persiste et s'accroît au fil du temps au fur et à mesure que l'algorithme reste en place. Une autre situation est également possible dans laquelle c'est cette fois-ci l'algorithme qui agit de manière opaque. Cette situation est illustrée fig. C.

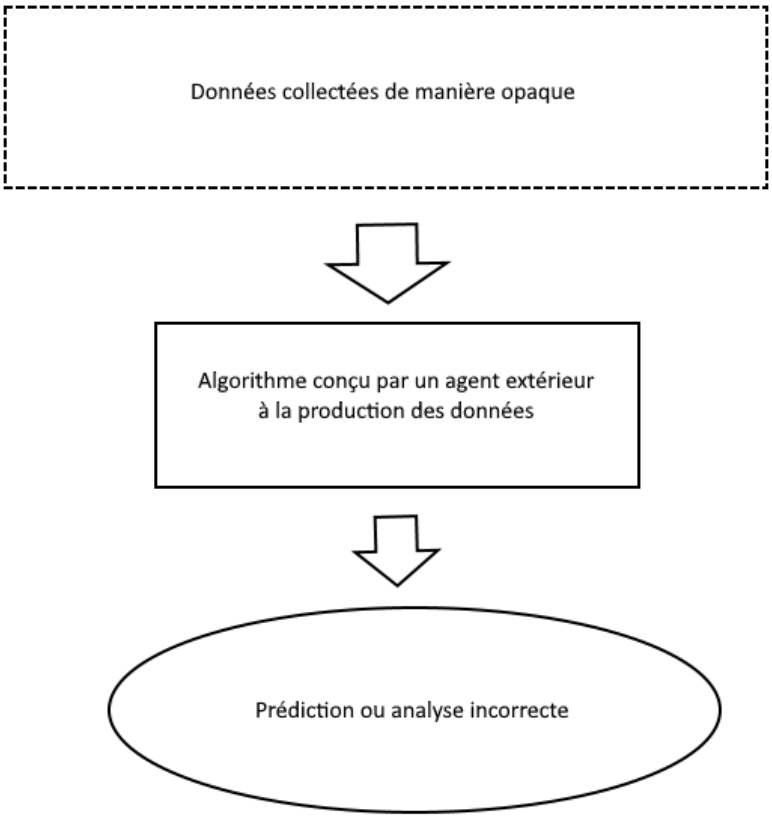


fig. B

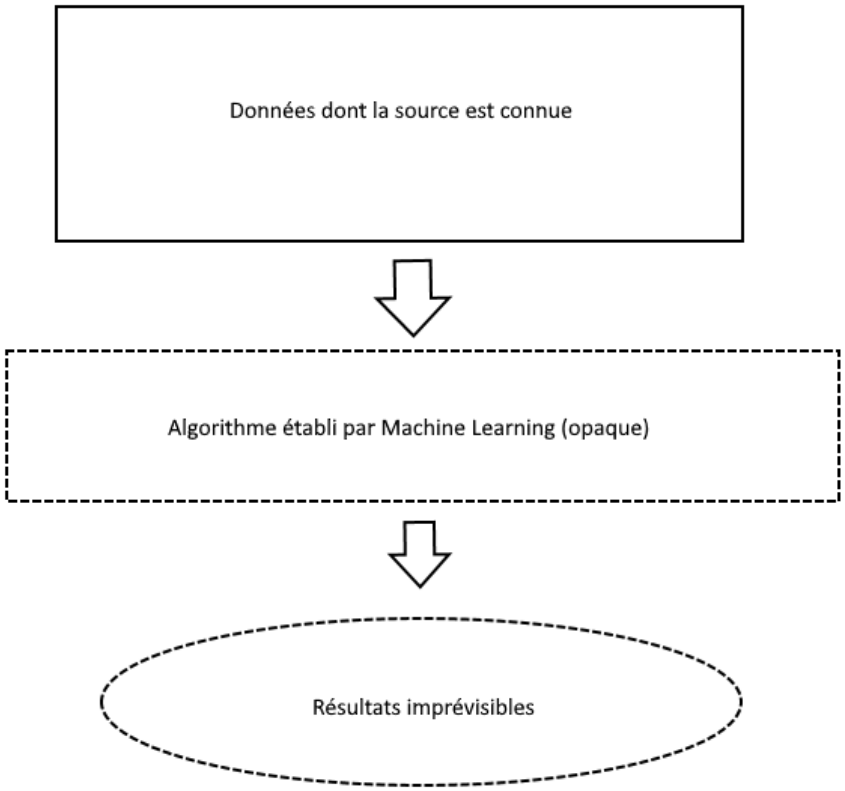


fig. C.

L'acteur humain n'a aucun poids dans le processus de décision de l'algorithme à cause de l'absence totale de transparence. C'est le cas par exemple des algorithmes obtenus dans le cadre de Deep Learning ou Machine Learning. Le cas le plus célèbre reste celui d'un algorithme de recrutement qui désavantageait certains profils racisés ou féminin pour des postes dans le secteur technologique. On a pu mettre en lien le comportement de l'algorithme avec le comportement historique des recruteurs. Il a été démontré que les algorithmes reproduisaient les comportements discriminatoires (Williams, 2018) qui avaient eu lieu par le passé. Une explication est que l'algorithme considère les données du passé et ce qui a réussi historiquement pour déterminer ce qui est bon pour le présent. De plus, les outils des Big Data Analytics nécessitent un nombre immense de données et sont donc pénalisés face à des changements brutaux de situations, dans lesquelles le nombre de données générées est insuffisant pour adapter l'algorithme.

3. Le danger d'une gouvernance opaque, qui rejette l'individualité

Le fait que les algorithmes de Machine Learning, et de Deep Learning engendrent des algorithmes opaques pour les acteurs humains qui le mettent en place a plusieurs conséquences, qui nous amènent à prendre nos précautions quant à l'application de ces outils pour les politiques publiques, voire certains processus impliquant la relation à l'autre, la gouvernance et la satisfaction des individus. La première de ces conséquences est le phénomène de "Boîte noire" (Pasquale, 2015). L'acteur humain n'est plus maître des décisions et ne connaît pas la logique de raisonnement à l'origine de la décision. Dans beaucoup de cas simples, ce fonctionnement est pertinent, et les décisions prises par l'algorithme sont cohérentes avec ce qui aurait pu être fait par un acteur humain. C'est le cas lorsqu'il y a un seul objectif précis (optimiser une variable résultante d'un processus complexe par exemple). Mais dans le cas où les objectifs sont multiples et de nature différentes, les solutions de Big Data Analytics sont nettement moins efficaces (Kopalle *et al.*, 2021), dans le cas où l'objectif est d'optimiser la satisfaction, la subjectivité de cette notion peut entraîner des résultats incorrects des algorithmes. La deuxième conséquence est le rejet de l'individualité (Janssen & Kuk, 2016). La faille principale du raisonnement des algorithmes Machine Learning, que l'on utilise beaucoup pour traiter les données, est qu'ils tentent d'approcher la notion de satisfaction des individus par la répétition de ce qui a fonctionné par le passé pour satisfaire un certain type d'individu. Il est encore très difficile de prendre en compte la complexité de l'individu, ce qui fait que le Machine Learning peut parfois donner des résultats surprenants lorsqu'il est chargé de conseiller une personne. L'utilisation de telles algorithmes est la conséquence d'une certaine vision des individus, possiblement en attribuant à chaque individu une "norme" de préférence. Réciproquement, afin de faire fonctionner les algorithmes, certaines entreprises (notamment dans le domaine des réseaux sociaux) peuvent essayer de mettre en place des mécanismes pour manipuler les utilisateurs et les influencer à adopter certains comportements. On peut alors assister peu à peu à la mise en place d'une "gouvernementalité" (notion développée par Foucault en 1997) brutale car il est aujourd'hui très difficile de se séparer des réseaux sociaux, ne serait-ce que pour ne pas

être coupé de la famille et des amis. Hors, les réseaux sociaux sont très vulnérables aux actions de manipulation de masse (Bruning et al., 2020) et sont également un lieu dans lequel les algorithmes sont très utilisés. Il est donc important de prévenir ce danger.

C. Vers un bien partagé ?

Dans cette quête d'une utilité du Big Data pour la société, la question de considérer les données comme un bien commun, partagé peut être sérieusement posée en ce que cette qualification permettrait un partage plus général des données.

1. La question du bien commun

Tout d'abord, un bien commun est caractérisé par sa non-exclusivité, c'est-à-dire qu'aucun agent économique ne peut être privé de la consommation de ce bien. De plus, il est également rival, cela signifie que le fait qu'un agent consomme ce bien peut empêcher un autre de le consommer. Il est donc souvent délivré par l'Etat en ce que tout le monde y a accès.

La production d'un bien commun au niveau mondial nécessite donc une certaine cohésion interétatique. En effet, sa gestion relève généralement des organismes supranationaux qui œuvrent ou sont censés œuvrer pour le bien commun (ONU, UE…).

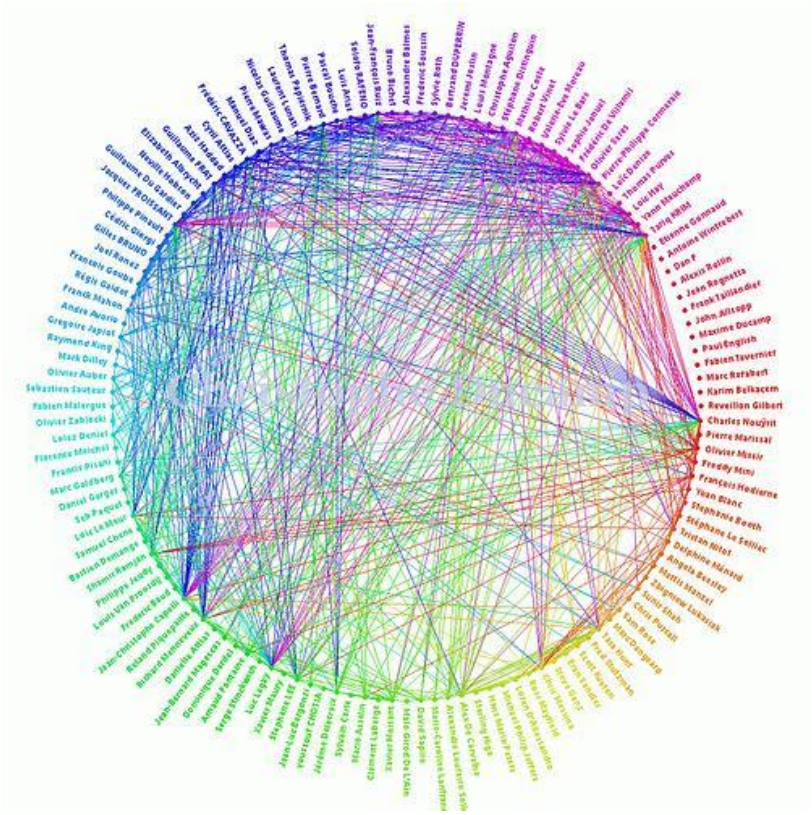
2. Qu'entend-on alors concrètement quand on parle des réseaux de données comme bien commun ?

Il est important dans un premier temps de bien comprendre qu'on ne parle pas de données directement mais de réseaux, cela permet de conserver une certaine confidentialité pour les utilisateurs concernés par le partage de leurs données. En effet, pour penser cette

conception de bien commun pour les réseaux, il convient de considérer ces réseaux comme des objets à part entière et non pas comme des regroupements de milliards de données.

Représentation schématique d'un réseau de données

Le caractère personnel des réseaux de données perd alors tout son sens en ce que chaque donnée du réseau renseigne sur bien plus qu'un seul individu, elle appartient donc à



la fois à tout le monde et à personne, caractéristique majeure du bien commun. Cette approche crée donc en droit un bien collectif qui est néanmoins soumis au droit individuel de chaque utilisateur qui reste maître dans une certaine mesure des informations qu'il fournit.

3. Quels avantages pourraient tirer les sociétés si les réseaux de données devenaient un bien commun ?

Tout d'abord, sur le plan environnemental, le regroupement de toutes les données mondiales permettrait de mieux appréhender les changements climatiques et de les combattre plus efficacement. Le regroupement et le partage de toutes les données relatives

à l'environnement serait également un moyen de prévoir et prévenir les catastrophes naturelles et d'être en mesure de protéger les territoires menacés par ces catastrophes.

Sur les plans sociétal et social, une telle organisation en bien commun permettrait de lutter plus efficacement contre la pauvreté en en comprenant mieux les causes, les conséquences et en mesurant l'efficacité des solutions apportées. De plus, comme a pu le montrer la pandémie de COVID-19, le partage des données scientifiques dans la recherche



pour un remède face à la maladie à la suite de la déclaration de l'OMS d' « état d'urgence de santé publique de portée internationale », a permis des avancées scientifiques remarquables en un temps record. Dès lors, le partage des données dans le secteur de la recherche semble également très important afin de répondre aux différents enjeux de santé publique mondiale notamment.

4. Pourquoi les réseaux de données ne deviennent-ils donc pas des biens communs ?

En France, la première tentative pour ériger les réseaux de données en biens communs date de 2016, époque où la député PS Delphine Batho au travers d'un amendement sur la loi informatique et libertés de 1978 avait soumis l'idée à l'assemblée, idée qui avait été rejetée. Comment expliquer ce rejet au niveau français comme au niveau international ?

Tout d'abord, les réseaux de données sont pour la plupart détenues par les entreprises et non les Etats qui contrairement à ces derniers possèdent souvent des motivations bien différentes (profit, compétitivité…), et ne recherche clairement pas en première instance le bien du plus grand nombre. Elles acquièrent difficilement toutes ces données et ne sont pas prêtes à renoncer à leur exclusivité.



Cependant, face à ce premier obstacle, on pourrait penser qu'une cohésion interétatique forte permettrait d'imposer des sanctions assez contraignantes pour inciter les entreprises à rendre leurs données récoltées publiques, mais cette cohésion est aujourd'hui complètement utopique, en ce que les intérêts nationaux pour les Etats priment sur tous les autres dans la majorité des cas (la guerre en Ukraine en est le parfait exemple).

C'est donc peut-être la société en tant que personne morale, mais aussi en tant que multitude de personnalités physiques qui doit changer de paradigme pour tendre vers une considération des réseaux en biens communs afin de permettre un plus grand changement de point de vue de la part des autres acteurs. Cela ne sera cependant possible que si les utilisateurs et donc producteurs de données parviennent à renoncer à la croyance de l'existence d'une donnée individuelle et personnelle au sein de réseaux, alors que ces dernières sont multi personnelles.

CONCLUSION

Nous avons établi dans ce rapport la définition du Big Data et le cadre technologique de son utilisation. Nous avons ensuite déterminé l'utilisation et les limites des technologies du Big Data concernant l'environnement et le développement social, mais également les nombreux bénéfices qu'il peut apporter à la vie de tous les jours. Il apparaît que la technologie du Big Data a encore besoin de nombreux cadres légaux et d'un effort étatique afin d'en assurer une utilisation responsable.

Dans ce rapport, nous avons commencé par rappeler la définition du Big Data (la donnée de masse), ainsi que le cadre technologique de son utilisation, et sa primauté actuelle. Mais rapidement, il est apparu que son utilisation n'était pas sans susciter de nombreux problèmes controversés. En effet, l'utilisation intensive du Big Data, telle qu'elle l'est aujourd'hui, exerce une pression sur l'environnement qui pose problème. Peut-on laisser la situation se poursuivre, voire s'amplifier ? Pire encore, les données soulève un problème d'un autre ordre : le côté éthique. En effet, ces données sont des données personnelles concernant les utilisateurs de tous les jours, autrement dit nous en tant que citoyens. Mais il y a un véritable problème à laisser ces données concernant notre vie privée être utilisées principalement par des entreprises dans le but de maximiser leurs profits. Enfin, ces données peuvent être utilisées par des gouvernements qui souhaitent modifier l'ordre occidentalo-centré établi. Ces puissances dites "révisionnistes" font du contrôle du Big Data un axe majeur de leur montée en puissance.

Pour autant, et c'est ici que le sujet est controversé, le Big Data apporte énormément au quotidien, et il serait aujourd'hui impensable de s'en passer. C'est en effet là-dessus que les entreprises du numérique, qui comptent aujourd'hui parmi les plus puissantes du monde, ont fondé leur succès. Ces entreprises n'apportent-elles pas emploi, vie économique et confort à nos sociétés ? Par ailleurs, les apports du Big Data se retrouvent dans bien d'autres domaines. On peut bien évidemment penser ici au sport, ou encore à la médecine.

Dès lors, que faire dans les faits ? La data est en effet une ressource largement détenue par des acteurs privés. C'est pourquoi nous pensons qu'il faut mettre en place un cadre légal pour contrôler cette donnée, ou bien l'anonymiser pour protéger les consommateurs. Car les limites au Big Data sont nombreuses : c'est une solution coûteuse, qui présente de nombreux

risques environnementaux, éthiques, ou encore technologiques. Finalement, nous pensons que la solution à ce problème controversé serait que ce Big Data devienne un bien commun. Mais pour ce faire, il faut un changement de point de vue de la part de tous les acteurs concernant ce sujet, que ce soient les sociétés, les entreprises ou encore les personnes.

ANNEXES

1. Les interviews

Interview d'Etienne Windels, Software Engineer chez Criteo

As-tu déjà travaillé sur un projet en lien avec le développement durable et les données ?

Non je pense que les projets data en développement durable sont encore assez rares en termes relatifs, même si en absolu ça a l'air de bien progresser. Je pense que cela vient notamment du fait qu'il y ait peu de données vraiment massives exploitables en rapport avec le développement durable pour le moment.

Quels sont selon toi les grands enjeux autour du Big Data ?

D'un point de vue personnel: maîtriser la consommation d'énergie lié au stockage et à l'exploitation des données puisque l'on s'engage dans un paradigme de sobriété assez peu compatible avec le profil des projets data. Sinon, plus généralement dans l'industrie, je pense que l'interprétabilité et la capacité à rapidement tirer de la valeur de nouvelles données sont très importantes.

Que penses-tu de l'aspect moral/éthique lié au big data ?

Je pense que la question n'a pas vraiment de sens étant donné la variété de données qui existe, ce serait comme poser une question sur l'aspect moral/éthique de la littérature. La réponse ne serait pas du tout la même si on parle de données utilisateurs à des fins politiques ou des données textuelles pour entraîner des modèles de langage, ou de la donnée image pour reconnaître des défauts sur des tomates.

Selon toi, les entreprises font-elles le nécessaire pour limiter les effets néfastes liés à l'exploitation des données ?

Je pense que, comme pour toute question éthique en business, on peut compter en partie sur la bienveillance des gens au sein et dans la direction des entreprises, mais la réalité est que, hors situation de monopole, si une entreprise se défavorise volontairement pour des raisons éthiques sans que ses concurrents n'aient à le faire, alors la loi du marché finira par donner raison aux concurrents. La seule solution pour moi vient du système légal dans lequel évoluent les entreprises. Quelque chose comme le RGPD n'aurait jamais été adopté aussi largement si ça n'avait pas été une contrainte légale. Cependant, on peut noter que toutes les entreprises ne lobbyent pas activement contre plus de contraintes et que les employés sont très généralement en faveur de législations favorables à la société au sens large même si désavantageux pour leur secteur d'activité.

Que pouvons nous attendre des entreprises vis-à-vis des enjeux du big data?

Nous pouvons attendre des progrès en terme de recherche, de valorisation des données, d'outils et de systèmes pour l'exploiter. Mais nous ne pouvons pas attendre des entreprises qu'elles décident spontanément de réduire leurs profits pour des considérations éthiques si les consommateurs ne sont pas prêts à récompenser les entreprises qui le font. La plupart des gens savent l'exploitation des données personnelles faites par Facebook ou Google mais acceptent tacitement en échange du service rendu.

Interview de Pierre Girard, chef de la division des services liés au tourisme à la direction générale de l'INSEE

Comment relevez-vous les données (par quels moyens) ?

Il y a plusieurs termes : moissonner, harvest ou scraper (racler). Le scrapping est ce qu'ils font parfois. Cela signifie récolter les traces numériques des personnes. Par exemple, si quelqu'un fait une réservation quelque part, il peut laisser un commentaire public. Il s'agit ici d'une trace numérique qu'ils peuvent capturer, puis en faire une statistique.

Comment traitez-vous d'une quantité de données conséquente pour produire une enquête ?

S'il y a une grosse masse de données, il n'y pas de difficulté. Par exemple, à la base des entreprises, ils gèrent un répertoire (SIREN), 14 millions de lignes, gros fichier, historique, et ils font des stats sur ce fichier grâce à la puissance informatique : il n'y aucun problème.
Ce qui pose un problème c'est toutes les infos qui sont internet et qui nécessitent d'être captées. Il faut les récolter, savoir lesquelles prendre et parfois il y a des problèmes. Ça peut être long, non pas en temps de calcul mais au niveau du temps qu'il faut pour accéder à la donnée. Il peut y avoir des problèmes si la connexion n'est pas bonne, si le serveur est saturé, si le site bloque l'accès. Ce n'est pas toujours facile... Ce n'est pas la puissance de l'ordi ou de la technologie qui bloque mais le pb est que c'est en réseau.

Après on peut se noyer il faut savoir précisément ce qu'on cherche, on est vite noyé. Donc c'est un peu un jeu de chat et de souris entre ceux qui récupèrent données et entreprises qui ne veulent pas donner accès. Par exemple : une plateforme de réservation d'hôtel va mettre en ligne des offres et certaines entreprises vont essayer de récupérer les données pour en faire indicateurs statistiques pour les revendre. Mais les entreprises qui mettent en ligne les annonces, quand quelqu'un se connecte pour récupérer données, ça ralentit les serveurs. Donc les entreprises vont identifier ceux qui viennent récupérer les données et vont les interdire. Ces moyens pour contrer sont assez efficaces : par exemple à l'INSEE ils ont organisé un hackaton, une compétition avec un objectif et une fois c'était sur le scrapping. Le but était

de créer le programme le plus efficace pour récupérer des données. Un employé de l'INSEE a créé un programme performant et donc l'entreprise a coupé tout accès à l'INSEE…

Y a-t-il donc un moyen optimal pour récupérer de la donnée ?

Le meilleur moyen pour récupérer de la donnée est d'être d'accord avec l'entreprise, qui transmet directement la donnée plutôt que de chercher de manière sauvage les données l'entreprise. Mais c'est assez facile de récupérer les données d'un point de vue technique, les outils sont très efficaces. Le problème est d'accéder à des données fiables. Par exemple pour le tourisme, un problème est le suivant : quand bcp de recherches de réservation sur Goggle, il y a une forte réservation hôtelière. Donc ils ont récupéré les recherches Google pour évaluer ça. Mais les recherches faites sur Google ne sont pas toutes transformées par du tourisme. Ce sont des intentions, mais il peut y avoir imprévu qui va faire que cette intention ne va pas être transformée : par ex avec le Covid, il y a eu beaucoup d'annulations. Donc il faut anticiper, mais c'est compliqué. Il faut toujours essayer de comparer le résultat du Big Data pour être sûr que ça dit la même chose.

Dans quelle mesure ces enquêtes permettent-elles d'avoir un avis objectif sur l'impact environnemental du tourisme en France ?

Pour le Big Data, il y a des choses qui existent avec les données de téléphonie mobile. A L'INSEE, ils mesurent s'il y a beaucoup d'activité humaine et donc en déduisent qu'il y a de la pression sur l'environnement. Il y a aussi des ratios sur la pression environnementale en termes de réservations : quand beaucoup de personnes logent dans un petit endroit, il y a un petit indicateur de pression environnementale. Certains statisticiens font ça : ils mesurent ainsi la pression environnementale qu'exerce l'activité humaine, et ceci n'est pas propre au tourisme. Et pour cela, il faut localiser les gens. C'est pour ça que les données téléphoniques sont utiles. Les opérateurs de téléphonie mobile peuvent calculer des indicateurs statistiques pour dire qu'il y a tant de téléphones mobiles dans cette zone.

Pour le tourisme, il se sert des commentaires laissés sur le site d'AirBnB et en fait des statistiques, des études. C'est très simple à faire, et bien utile quand ils n'ont pas d'autres données, car c'est peu coûteux mais peu précis et très fragile.

Interview d'Isabelle Beyneix, professeure de droit à l'ESCP, spécialisée dans le Big Data, professeur d'un cours sur les Data et la Blockchain de 300 élèves

Qu'est-ce qui est actuellement en place pour protéger notre vie privée ?

Il y a un texte européen, le RGPD mais il a plein de failles sur certains points. Il y a un règlement européen qui peut apporter une solution pour le consentement, il suffirait de donner son consentement une seule fois par session de navigateur, mais beaucoup d'entreprises ne sont pas d'accord avec ça. Notamment Webedia qui vous proposent soit d'abandonner nos données si l'on veut pas payer. On a réussi à se mettre d'accord sur un texte [européen], comme pour l'instant nous sommes les grands perdants, comme vous le savez les données remontent aux Etats-Unis. Pour avoir une vie privée, il faudrait utiliser Qwant ou DuckDuckGo, Mastodont pour les réseaux sociaux, d'autres boîtes mail… Beaucoup de gens ne prennent pas au sérieux l'adage "Quand c'est gratuit, c'est toi le produit". Il y a encore 47% des français qui acceptent de partager toutes les données sans comprendre à quoi ça peut mener.

Il y a un vrai scandale par rapport à Doctolib, leur vraie valorisation c'est vos données qui circulent alors que normalement selon le RGPD elles devraient être hors du marché européen comme données sensibles. Une étudiante m'a parlé de son stage à Doctolib… C'est hallucinant. Generali vous offre des ristournes en échange de vos données. Les données sont également piratées dans les hôpitaux. Les assureurs automobiles vous proposent une boîte noire dans la voiture pour surveiller la manière dont vous conduisez pour fixer le prix de l'assurance, donc il y a vraiment une intrusion dans la vie privée pour des besoins économiques qui ne sont pas toujours pertinents et qui ne sont pas toujours pour la protection du citoyen. C'est difficile de faire passer les lois en interne et au niveau européen. La CNIL est renforcée, mais on a problème, c'est les Etats-Unis qui prennent tout ce qui les intéresse. Jusqu'à Cambridge Analytica, ça n'intéressait pas les foules. Les utilisateurs ont répondu à un questionnaire sur les opinions politiques puis ont été ciblés. Il y a des grosses boîtes de brokers de données (revente de données). On a beaucoup d'influence des Etats-Unis. Il y a un premier texte, le safe harbor. L'activiste Max Schrems a réussi à le faire tomber via la commission européenne. Il continue à se battre contre les mesures facilitant le transfert des données aux États-Unis. Notre RGPD est quelque chose d'unique. Un autre problème qu'on c'est l'extraterritorialité du droit américain. Deux textes nous ont causé beaucoup de

mal, le Patriot Act et le Cloud Data Act. Je vous conseille le livre de l'ancien président d'Alstom. L'Etat français a des projets de cloud français (OVH) mais on reste très dépendants des américains.

Y a-t-il des entreprises qui ne respectent pas le RGPD?

Il y a un détournement du RGPD, le Consentement Managing Platforms (CMP) sont des entreprises de pub qui gèrent l'implémentation du RGPD.

Interview de Max Métral, ancien Insights Analyst en Formule et pour Manchester City

Selon vous, depuis quand y'a-t-il un lien entre le sport et l'analyse des données ?

Il y'a eu deux types d'analyses dans l'industrie du sport : « sport analytics » via les statistiques sont apparus au baseball dans les années 70 avant d'être popularisé par le livre Moneyball de Michael Lewis. Ensuite la « business analytics » dans l'industrie du sport est apparue. Les équipes se préoccupent de comment améliorer leur performance en tant qu'entreprise.

A travers nos recherches, nous avons remarqué que les résultats sportifs ne sont plus seulement liés à l'activité sportive en elle-même mais aussi à l'analyse des données, pouvez nous en dire plus ?

Depuis quelques années, une tendance est apparue. Celle de nommer comme directeur général des jeunes diplômés d'une formation d'analyse des données. C'est le cas par exemple de Daryl Morey (76ers, NBA) ou de Farhan Zaidi (Giants, MLB). Ils sont considérés comme des « datas nerds » et ont un rôle crucial dans le développement de l'industrie sportive. Ces personnes ne sont pas des magiciens mais sont tout simplement meilleurs pour prendre des décisions. En effet, leurs algorithmes et l'analyse des données qui en découlent surpassent toute intuition humaine. Par exemple, prenons le domaine du recrutement. Un recruteur classique se fait une opinion sur un joueur. Dès lors, il arrangera les preuves pour soutenir son opinion. C'est ce qu'on appelle le biais de confirmation. L'analyse des données est là pour rectifier le tir.

A l'avenir, les data analysts seront-ils plus importants que les joueurs ?

Les « datas nerds » ne sont pas des magiciens. Si des joueurs comme Kareem Abdul Jabbar ou Lebron James ont changé l'histoire de leur sport ou même des entraîneurs comme Pep Guardiola ou Hal Mumme (entraîneur de football en NCAA), ce n'est pas vraiment le cas des « datas nerds ». De plus, il est de plus en plus difficile de trouver un avantage avec l'analyse des données. En revanche, leur expertise est à prendre au sérieux et sont importants dans une équipe, comme l'a relaté le livre à succès Moneyball.

Vous m'avez parlé au début d'un autre type d'analyse dans l'industrie sportive : l'analyse commerciale. Avez-vous un exemple ?

Il y a par exemple la tarification dynamique. Il faut que pour la plupart des franchises sportives, surtout pour les équipes disputant de nombreux matchs à domicile, la billetterie est une source majeure des revenus de la franchise. Par exemple, en Major League Baseball (MLB), les équipes disputent chacune 81 matchs à domicile. Dès lors, il est important de trouver le juste prix pour un billet. La tarification dynamique a ainsi été mise en place dans la plupart des franchises, même si certaines équipes, notamment dans le championnat de football anglais, n'ont pas besoin d'utiliser la tarification dynamique car elles n'ont aucun problème à remplir les stades. Celle-ci utilise des algorithmes pour mesurer la demande et la sensibilité des prix par rapport à un match. De nombreux facteurs sont pris en compte, tels que la météo, une série de victoires de l'équipe, le jour de la semaine, l'heure du match, etc

Nous avons vu que l'analyse sportive avait eu une grande influence sur l'industrie sportive, est-ce également le cas concernant l'analyse commerciale ?

L'analyse commerciale dans l'industrie sportive n'est pas aussi avancée que l'analyse sportive. Cependant, elle est très utile pour les franchises sportives. Elle permet par exemple de calculer son retour sur investissement avec ses sponsors ou encore de fidéliser toujours plus de fans. La révolution de l'analyse commerciale avance doucement, mais sûrement. Personnellement, lorsque je travaillais pour Manchester City ou en F1, j'ai toujours été du côté du business analytics .

Pouvez vous nous en dire plus sur ton rôle en F1 par exemple ?

Je faisais partie d'une équipe qu'on appelle Insights Analytics, un mot difficile à traduire en français. L'objectif est d'aider les différent départementaux commerciaux à prendre de meilleures décisions grâce à une analyse de données. Je ne touchais pas du tout aux données concernant les voitures. Personnellement, je gérais plus le côté analyse pure, mon job c'est surtout de faire le lien entre les différents départements. Mes clients étaient les différents directeurs de la F1, je devais leur vendre des projets pour ensuite les mettre à bien. Mon rôle était vraiment de faire l'intermédiaire. Par exemple, mon rôle ainsi que celui de mon équipe était d'optimiser l'heure de départ d'un grand prix pour essayer de convenir aux plus grand nombre de fans dans le monde entier

Pour finir, quelles sont les tendances selon toi qui vont se révéler pour les prochaines années ?

Ça va continuer. Sur l'aspect Sport Analytics, le plus important c'est la collecte de données. Leur but, c'est d'avoir des données qui sont uniques, plus complètes. Sur l'aspect commercial, ça va continuer à se développer progressivement. Dans 10,15 ans, je pense qu'il n'y aura plus d'équipes spécialisées dans l'analyse des données mais la donnée va s'intégrer dans tous les domaines. Cela fera partie du job de tout le monde.

Interview de Camille, étudiant en Master en Data & AI à HETIC, ancien stagiaire à Facebook

Quels sont les plus gros enjeux que l'on a en Data?

On a de plus en plus de Data qui viennent de pleins de sources différentes qui constituent une rente accessible et uniforme. L'autre enjeux est de constituer des persona avec des méthode en accord avec le RGPD

Quels sont les problèmes éthiques?

On peut avoir pas mal d'informations, comme la situation géographique, c'est quelque chose qui émerge, comment gérer les Data de façon éthique.

C'est en réponse à des abus?

Oui, lorsque j'étais en stage à Facebook, j'ai découvert à quel point il était facile de suivre une personne à la trace. C'est quelque chose sur lequel il faut légiférer, c'est pour moi la seule solution.

2. La bibliographie

Bordage, F. (2019), Empreinte environnementale du numérique mondial, GreenIT.fr, September

Bibri, S. E. (2019). On the sustainability of smart and smarter cities in the era of big data: an interdisciplinary and transdisciplinary literature review. Journal of Big Data, 6(1)

Meiyou, D. & Y. Ye (2022). Establishment of big data evaluation model for green and sustainable development of enterprises. Journal of King Saud University

Wu, J., Guo, S., Li, J. and Zeng, D. (2016). Big Data Meet Green Challenges: Greening Big Data. [online] ResearchGate

Peng, X., Bhattacharya, T., Cao, T., Mao, J., Tekreeti, T. and Qin, X. (2022). Exploiting Renewable Energy and UPS Systems to Reduce Power Consumption in Data Centers. Big Data Research, [online] 27, p.100306. doi:10.1016/j.bdr.2021.100306.

Papadopoulos, T. and Balta, M.E. (2022). Climate Change and big data analytics: Challenges and opportunities. International Journal of Information Management, [online] 63, p.102448. doi:10.1016/j.ijinfomgt.2021.102448.

Steinberg, E. (2019). Big Data and Personalized Pricing. Business Ethics Quarterly, [online] 30(1), pp.97–117. doi:10.1017/beq.2019.19.

Katal, A., Dahiya, S. and Choudhury, T. (2022). Energy efficiency in cloud computing data centers: a survey on software technologies. Cluster Computing. [online] doi:10.1007/s10586-022-03713-0.

Lucivero, F. (2019). Big Data, Big Waste? A Reflection on the Environmental Sustainability of Big Data Initiatives. Science and Engineering Ethics, [online] 26(2), pp.1009–1030. doi:10.1007/s11948-019-00171-7.

McNerney, M. (2019). The Data Center Dilemma: Is Our Data Destroying the Environment? [online] Data Center Knowledge | News and analysis for the data center industry. Available at: https://www.datacenterknowledge.com/industry-perspectives/data-center-dilemma-our-data-destroying-environment [Accessed 4 Nov. 2022].

R, A. (2022). Data Centers Hyperscale : définition, constitution et avantages - LeBigData.fr. [online] LeBigData.fr. Available at: https://www.lebigdata.fr/data-centers-hyperscale-definition [Accessed 4 Nov. 2022].

Labidoire, B. (2022). Comment les données de l'entreprise peuvent répondre au défi climatique ? [online] Journaldunet.com. Available at: https://www.journaldunet.com/web-tech/developpeur/1509119-comment-les-donnees-de-l-entreprise-peuvent-repondre-au-defi-climatique/ [Accessed 4 Nov. 2022].

Hamami, O. (2014) Big Data Security: Understanding the Risks - BUSINESS INTELLIGENCE JOURNAL • VOL. 19, NO. 2

Laurent Cytermann (2015). Promesses et risques de l'open et du big data : les réponses du droit. Informations sociales, [online] 191(5), pp.80–90. Available at: https://www.cairn.info/revue-informations-sociales-2015-5-page-80.htm [Accessed 4 Nov. 2022].

Lebaron, F. (2021). Quels enjeux socio-économiques pour les données des sciences sociales ? Revue internationale de droit economique, [online] (3), pp.9–18. Available at: https://www.cairn.info/revue-internationale-de-droit-economique-2021-3-page-9.htm [Accessed 4 Nov. 2022].

Bersales, L.G.S., Almeda, J.V., Romasoc, S.O., Martinez, M.N.R. and Galias, D.J.B. (2021). Big Data in the Philippines: How do we actually use them? Statistical Journal of the IAOS, [online] 37(4), pp.1347–1377. doi:10.3233/sji-210826.

Anaïs Theviot (2018). 'Une économie de la promesse' : mythes et croyances pour vendre du Big data électoral. Les Enjeux de l'information et de la communication, [online]

192(2), pp.45–55. Available at: https://www.cairn.info/revue-les-enjeux-de-l-information-et-de-la-communication-2018-2-page-45.htm [Accessed 4 Nov. 2022].

K. Kalaiselvi and Raja, A. (2020). Big Data Analytics and Intelligence: A Perspective for Health Care

Pierre-Yves Longaretti and Berthoud, F. (2021). Le numérique, espoir pour la transition écologique ? L'Economie politique, [online] 90(2), pp.8–22. Available at: https://www.cairn.info/revue-l-economie-politique-2021-2-page-8.htm [Accessed 4 Nov. 2022].

Didier Mallarino, Sylvie Le Bras and Cyrille Bonamy (2022). Les impacts environnementaux et sociétaux des données : un défi pour l'avenir. Archives-ouvertes.fr. [online] doi:https://hal.archives-ouvertes.fr/hal-03702208.

Carnino, G. & Marquet, C. (2018). Les datacenters enfoncent le cloud : enjeux politiques et impacts environnementaux d'internet. Zilsel, 3, 19-62. https://doi.org/10.3917/zil.003.0019

Gudivada, V. N. (2017). Data Analytics. *Data Analytics for Intelligent Transportation Systems*, 31–67. https://doi.org/10.1016/b978-0-12-809715-1.00002-x

Galetsi, P., Katsaliaki, K., & Kumar, S. (2022). The medical and societal impact of big data analytics and artificial intelligence applications in combating pandemics: A review focused on Covid-19. *Social Science & Medicine*, *301*, 114973. https://doi.org/10.1016/j.socscimed.2022.114973

Mehta, B. B., & Rao, U. P. (2022). Improved l-diversity: Scalable anonymization approach for Privacy Preserving Big Data Publishing. *Journal of King Saud University - Computer and Information Sciences*, *34*(4), 1423–1430. https://doi.org/10.1016/j.jksuci.2019.08.006

Usha Lawrance, J., & Nayahi Jesudhasan, J. V. (2021). Privacy Preserving Parallel Clustering Based Anonymization for Big Data Using MapReduce Framework. Applied Artificial Intelligence, 35(15), 1587–1620. https://doi-org.revproxy.escpeurope.eu/10.1080/08839514.2021.1987709

Bibri, S. E. (2019). On the sustainability of smart and smarter cities in the era of big data: an interdisciplinary and transdisciplinary literature review. *Journal of Big Data*, *6*(1). https://doi.org/10.1186/s40537-019-0182-7

Global predictive analytics market size 2028 | Statista. (2022). Statista; Statista. https://www-statista-com.revproxy.escpeurope.eu/statistics/1286871/predictive-analytics-market-size/

Williams, B. A., Brooks, C. F., & Shmargad, Y. (2018). How Algorithms Discriminate Based on Data They Lack: Challenges, Solutions, and Policy Implications. *Journal of Information Policy*, *8*, 78–115. https://doi.org/10.5325/jinfopoli.8.2018.0078

PASQUALE, F. (2015). The Black Box Society: The Secret Algorithms That Control Money and Information. Harvard University Press. http://www.jstor.org/stable/j.ctt13x0hch

Janssen, M., & Kuk, G. (2016). The challenges and limits of big data algorithms in technocratic governance. *Government Information Quarterly*, *33*(3), 371–377. https://doi.org/10.1016/j.giq.2016.08.011

Arpin, I. (2020). Les producteurs professionnels de données sur la biodiversité face aux “big data” en écologie. *Natures Sciences Societes*, *28*(1), 66–72. https://www-

cairn-info.revproxy.escpeurope.eu/revue-natures-sciences-societes-2020-1-page-66.htm

Devictor, V., & Bensaude-Vincent, B. (2016). From ecological records to big data: the invention of global biodiversity. *History and Philosophy of the Life Sciences*, *38*(4). https://doi.org/10.1007/s40656-016-0113-2

Kopalle, P. K., & Lehmann, D. R. (2021). Big Data, Marketing Analytics, and Public Policy: Implications for Health Care. Journal of Public Policy & Marketing, 40(4), 453–456. https://doi-org.revproxy.escpeurope.eu/10.1177/0743915621999031

Saldanha, D. M. F., Dias, C. N., & Guillaumon, S. (2022). Transparency and accountability in digital public services: Learning from the Brazilian cases. *Government Information Quarterly*, *39*(2), 101680. https://doi.org/10.1016/j.giq.2022.101680

Haque, A. B., Islam, A. K. M. N., & Mikalef, P. (2023). Explainable Artificial Intelligence (XAI) from a user perspective: A synthesis of prior literature and problematizing avenues for future research. *Technological Forecasting and Social Change*, *186*, 122120. https://doi.org/10.1016/j.techfore.2022.122120

Zhang, C. (Abigail), Cho, S., & Vasarhelyi, M. (2022). Explainable Artificial Intelligence (XAI) in auditing. *International Journal of Accounting Information Systems*, *46*, 100572. https://doi.org/10.1016/j.accinf.2022.100572

Bag, S., Rahman, M. S., Srivastava, G., Chan, H.-L., & Bryde, D. J. (2022). The role of big data and predictive analytics in developing a resilient supply chain network in the South African mining industry against extreme weather events. *International*

Journal of Production Economics, *251*, 108541. https://doi.org/10.1016/j.ijpe.2022.108541

Mansour, R. F. (2016). Understanding how big data leads to social networking vulnerability. *Computers in Human Behavior*, *57*, 348–351. https://doi.org/10.1016/j.chb.2015.12.055

M. Kosinski, D. Stillwell, T. Graepel Private traits and attributes are predictable from digital records of human behavior Proceedings of the National Academy of Sciences, 110 (15) (2013), pp. 5802-5805

Bruning, P. F., Alge, B. J., & Lin, H.-C. (2020). Social networks and social media: Understanding and managing influence vulnerability in a connected society. *Business Horizons*, *63*(6), 749–761. https://doi.org/10.1016/j.bushor.2020.07.007

Isaac, H. (2018). "La donnée numérique, bien public ou instrument de profit", *Pouvoirs (164)*, 75-86.

https://www.cairn.info/revue-pouvoirs-2018-1-page-75.htm?contenu=article

Wylie, C. (2020). *Mindfuck : Le complot de Cambridge Analytica pour s'emparer de nos cerveaux.*

Kaiser, B. (2020). *L'affaire Cambridge Analytica. L'entreprise qui a siphonné des données de 87 millions d'utilisateurs.*

Parlement européen. (2016). *RGPD.*

Laïdi, A. (2021). *Le droit, nouvelle arme de guerre économique. Comment les Etats-Unis déstabilisent les entreprises européennes*.

Kant, E. (1785). *Fondements de la métaphysique des mœurs*.

Mill, J.S. (1861). *L'utilitarisme*.

Jonas, H. (1979). *Le Principe responsabilité*.

Orlowsky, J. (2020), *Derrière nos écrans de fumée*

Walker, C. and Ludwig, J. (2020), "*The cutting Edge of Sharp Power*", *Journal of Democracy*

Rifkin, J. (2012), *La troisième Révolution Industrielle*

Schwab, K. (2017), *La quatrième Révolution Industrielle*

Zuboff, S. (2020), *L'âge du capitalisme de surveillance*